

DÉTECTION PRÉCOCE DE LA MALADIE D'ALZHEIMER PAR MACHINE LEARNING ET DEEP LEARNING À PARTIR DES DONNÉES ADNI

RNCP 35288 – Niveau 6 (Bac+4)

Projet réalisé par

- Bruce VIGNOLLES
- Assmaa ABDELMOUMNI
- Magalie CESARINI

Formation Concepteur Développeur en Science des Données – M2i Formation

INTRODUCTION GÉNÉRALE

Contexte

La maladie d'Alzheimer représente aujourd'hui l'un des principaux défis de santé publique liés au vieillissement de la population. Son évolution progressive et souvent silencieuse rend difficile l'identification des patients à risque lors des premiers stades de la maladie. Pourtant, une détection précoce peut contribuer à améliorer le suivi médical, faciliter l'orientation des patients et permettre une prise en charge plus adaptée.

Parallèlement, les professionnels de santé disposent d'un volume croissant d'informations médicales provenant de sources variées : examens cognitifs, données démographiques, constantes physiologiques, antécédents médicaux ou encore imagerie cérébrale. Bien que riches en informations, ces données sont souvent dispersées et complexes à exploiter dans leur globalité.

Dans ce contexte, les approches de gestion et de valorisation des données offrent de nouvelles perspectives. Elles permettent de transformer des données médicales hétérogènes en informations exploitables susceptibles d'accompagner les professionnels de santé dans leurs analyses et leurs prises de décision.

Présentation du projet

Dans le cadre de ce projet, nous nous positionnons comme une équipe spécialisée dans la gestion et la valorisation des données de santé intervenant en appui d'une équipe médicale.

L'équipe médicale souhaite disposer d'un outil capable d'analyser simultanément plusieurs dimensions du dossier patient afin d'identifier plus rapidement les profils susceptibles de présenter un risque de développer la maladie d'Alzheimer.

Pour répondre à ce besoin, nous avons développé un Proof of Concept (POC) reposant sur les données du programme ADNI (Alzheimer's Disease Neuroimaging Initiative), l'une des

principales bases de données internationales dédiées à l'étude des maladies neurodégénératives.

L'objectif du projet n'est pas de remplacer le diagnostic médical mais de démontrer la faisabilité d'une solution capable d'exploiter efficacement des données médicales complexes afin de produire une estimation du risque Alzheimer et de fournir une aide complémentaire à la décision.

Problématique

Comment exploiter un volume important de données médicales hétérogènes afin de concevoir une solution d'aide à la décision capable d'identifier précocement les patients présentant un risque de développer la maladie d'Alzheimer tout en garantissant l'interprétabilité des résultats pour les professionnels de santé ?

Cette problématique soulève plusieurs défis :

- sélectionner les informations pertinentes parmi plusieurs centaines de variables disponibles ;
- consolider des données issues de sources multiples ;
- transformer les données brutes en indicateurs à valeur ajoutée ;
- développer des modèles prédictifs fiables et interprétables ;
- rendre les résultats accessibles à travers des outils adaptés aux utilisateurs.

Objectifs du projet

Afin de répondre à cette problématique, nous avons défini plusieurs objectifs :

- construire un référentiel de données cohérent à partir des données ADNI ;
- identifier les principaux facteurs associés au risque Alzheimer ;
- développer une solution prédictive permettant d'estimer ce risque ;
- mettre à disposition une interface simple d'utilisation ;
- fournir des outils de visualisation facilitant l'interprétation des résultats ;
- démontrer la faisabilité technique et fonctionnelle d'une telle solution dans un contexte de santé.

Démarche retenue

Notre démarche repose sur cinq grandes étapes :

1. Cadrage et gouvernance du projet ;

2. Gestion et valorisation des données ;
3. Analyse et création de connaissances ;
4. Conception de la solution prédictive ;
5. Industrialisation et communication des résultats.

L'ensemble de ces étapes a été conduit selon une approche itérative inspirée des méthodes Agile.

Structure du rapport

Le présent rapport décrit l'ensemble de la démarche mise en œuvre pour répondre au besoin exprimé par l'équipe médicale.

Le premier chapitre présente le cadrage du projet, les parties prenantes ainsi que les mécanismes de gouvernance mis en place.

Le deuxième chapitre détaille la stratégie de gestion des données et les arbitrages réalisés lors de la constitution du référentiel de données.

Le troisième chapitre expose les principaux enseignements issus de l'analyse des données ainsi que la création d'indicateurs complémentaires.

Le quatrième chapitre présente la conception de la solution prédictive et les choix réalisés lors de la sélection du modèle final.

Le cinquième chapitre est consacré à l'industrialisation de la solution et à son déploiement.

Le sixième chapitre présente l'organisation Agile du projet et les activités de pilotage réalisées tout au long des travaux.

Enfin, le dernier chapitre est consacré à la communication des résultats, aux limites identifiées et aux perspectives d'évolution de la solution.

CHAPITRE 1 – GOUVERNANCE ET CADRAGE DU PROJET

1.1 Présentation du besoin

L'équipe médicale partenaire du projet souhaite disposer d'un outil capable d'exploiter automatiquement un ensemble de données médicales afin d'identifier les patients susceptibles de présenter un risque de développer la maladie d'Alzheimer.

Aujourd'hui, les informations disponibles sont nombreuses mais réparties entre différentes sources : examens cognitifs, données physiologiques, antécédents médicaux ou encore mesures issues de l'imagerie cérébrale. Leur analyse globale nécessite du temps et mobilise une expertise importante.

Dans ce contexte, notre mission consiste à étudier la faisabilité d'une solution capable de centraliser ces informations, d'en extraire les signaux les plus pertinents et de restituer les résultats sous une forme exploitable par les professionnels de santé.

L'objectif n'est pas de produire un diagnostic automatisé mais d'apporter un outil d'aide à la décision permettant de compléter l'analyse clinique réalisée par les médecins.

1.2 Parties prenantes du projet

Le projet mobilise plusieurs catégories d'acteurs ayant des attentes et des responsabilités différentes.

Équipe médicale

L'équipe médicale est à l'origine du besoin fonctionnel. Elle définit les objectifs métier, apporte son expertise sur les indicateurs utilisés et reste responsable de l'interprétation clinique des résultats.

Son rôle est également de s'assurer que les informations produites par la solution sont cohérentes avec les connaissances médicales actuelles.

Équipe projet Data

Notre équipe est chargée de concevoir, développer et déployer le Proof of Concept.

Elle est composée de :

- Magalie Césarini ;
- Bruce Vignolles ;
- Assmaa Abdelmoumni.

Nos responsabilités couvrent l'ensemble du cycle de valorisation des données :

- analyse du besoin ;

- sélection des données ;
- préparation et consolidation ;
- analyse exploratoire ;
- conception des modèles ;
- industrialisation de la solution ;
- restitution des résultats.

Utilisateurs finaux

Les utilisateurs finaux sont les professionnels de santé amenés à consulter les résultats produits par la solution.

Ils utilisent les indicateurs, visualisations et estimations générés comme éléments complémentaires à leur expertise clinique.

1.3 Organisation du projet

Afin de structurer les travaux et de garantir un suivi régulier de l'avancement, nous avons adopté une organisation inspirée de la méthodologie Agile Scrum.

Cette approche présente plusieurs avantages :

- découpage du projet en objectifs intermédiaires ;
- visibilité sur l'avancement ;
- adaptation progressive aux difficultés rencontrées ;
- amélioration continue des livrables.

Le projet a été organisé autour de plusieurs sprints successifs permettant de planifier les activités et de valider progressivement les différentes briques de la solution.

Utilisation de Jira

Le suivi opérationnel du projet a été assuré à l'aide de Jira.

Cet outil nous a permis de centraliser :

- les User Stories ;
- les tâches techniques ;
- les anomalies identifiées ;
- les critères d'acceptation ;

- les livrables produits.

L'utilisation du backlog, du tableau Kanban et des indicateurs de suivi a facilité le pilotage quotidien des activités.

Rotation des rôles Scrum

Dans une logique de partage des responsabilités et de montée en compétence collective, les rôles de Scrum Master et de Product Owner n'ont pas été attribués de manière permanente.

À chaque sprint, ces responsabilités ont été redistribuées entre les membres de l'équipe.

Cette organisation a permis à chacun d'intervenir sur :

- la gestion du backlog ;
- la priorisation des besoins ;
- la coordination des activités ;
- l'animation des réunions ;
- la validation des livrables.

La rotation des rôles a contribué à renforcer la polyvalence de l'équipe et à développer une compréhension globale des enjeux du projet.

1.4 Gestion des risques

La réussite du projet reposait sur notre capacité à identifier rapidement les principaux risques susceptibles d'impacter les délais, la qualité des résultats ou la faisabilité de la solution.

Plusieurs risques ont été identifiés dès les premières phases du projet.

Complexité des données

La base ADNI contient plusieurs centaines de variables réparties dans de nombreuses tables.

Le principal risque consistait à construire une solution trop complexe ou difficilement exploitable.

Pour limiter ce risque, nous avons défini un périmètre fonctionnel précis reposant sur les tables les plus pertinentes au regard de la problématique étudiée.

Qualité des données

Les données médicales comportent naturellement des valeurs manquantes, des codifications spécifiques et des niveaux de complétude variables.

Des contrôles qualité ont été réalisés tout au long du projet afin de garantir la cohérence des informations utilisées.

Risque de surapprentissage

L'utilisation d'un grand nombre de variables pouvait conduire à la création d'un modèle trop spécialisé sur les données d'entraînement.

Une sélection progressive des variables a donc été réalisée afin de conserver un équilibre entre performance et capacité de généralisation.

Risques liés au déploiement

Le projet reposant sur plusieurs composants techniques interconnectés, nous avons également pris en compte les risques liés à l'intégration et à la disponibilité des services.

Des tests réguliers ont été effectués afin de valider le bon fonctionnement des différentes briques de l'architecture.

Protection des données

Bien que les données ADNI soient pseudonymisées, nous avons intégré dès le début du projet une réflexion sur la protection des données et les principes du RGPD.

Cette démarche a conduit à la réalisation d'une analyse d'impact relative à la protection des données (PIA).

1.5 Facteurs clés de succès

Plusieurs éléments ont contribué à la réussite du projet.

Le premier facteur réside dans la définition d'un périmètre clair permettant de concentrer les efforts sur les données les plus pertinentes.

Le second facteur concerne l'organisation Agile mise en place, qui a facilité la coordination des travaux et l'adaptation aux difficultés rencontrées.

La communication régulière entre les membres de l'équipe a également joué un rôle essentiel dans la résolution rapide des problèmes techniques et organisationnels.

Enfin, l'approche progressive adoptée tout au long du projet a permis de valider les choix réalisés au fur et à mesure de l'avancement des travaux et de limiter les risques associés aux développements tardifs.

1.6 Conclusion du chapitre

Cette phase de cadrage a permis de définir les objectifs du projet, d'identifier les parties prenantes et de mettre en place les mécanismes de gouvernance nécessaires à sa réalisation.

Les décisions prises durant cette étape ont servi de cadre à l'ensemble des travaux présentés dans les chapitres suivants et ont contribué à sécuriser la réalisation du Proof of Concept.

CHAPITRE 2 – STRATÉGIE DE GESTION DES DONNÉES

2.1 Compréhension du patrimoine de données

La première phase du projet a consisté à analyser les données mises à disposition par le programme ADNI (Alzheimer's Disease Neuroimaging Initiative).

ADNI est une initiative de recherche internationale visant à mieux comprendre les mécanismes de la maladie d'Alzheimer grâce à la collecte de données longitudinales provenant de plusieurs milliers de participants suivis sur plusieurs années.

Les données disponibles couvrent de nombreux domaines médicaux :

- caractéristiques démographiques ;
- évaluations cognitives ;
- examens neuropsychologiques ;
- antécédents médicaux ;
- antécédents familiaux ;
- mesures physiologiques ;
- biomarqueurs ;
- imagerie cérébrale.

Cette richesse constitue un atout majeur pour la recherche mais représente également un défi important pour les projets de valorisation des données. Le volume de données disponible et le nombre élevé de variables rendent difficile une exploitation exhaustive dans le cadre d'un Proof of Concept.

Notre première mission a donc consisté à identifier les informations les plus pertinentes au regard du besoin exprimé par les professionnels de santé.

2.2 Définition du périmètre de données

Afin de conserver un périmètre cohérent et exploitable, nous avons procédé à une sélection progressive des sources de données.

Cette sélection a été réalisée selon plusieurs critères :

- pertinence clinique ;
- qualité des données ;
- disponibilité des informations ;

- capacité d'interprétation par les professionnels de santé ;
- potentiel prédictif.

À l'issue de cette phase, dix tables ont été retenues afin de couvrir les principales dimensions médicales associées à la maladie d'Alzheimer.

Données cognitives

Les tables MMSE, ADAS et CDR regroupent les principales évaluations cognitives utilisées pour mesurer les capacités mnésiques et fonctionnelles des patients.

Ces données constituent le socle principal de l'analyse.

Données médicales et contextuelles

Les tables PTDEMOG, MEDHIST, INITHEALTH et FAMHXPAP apportent des informations relatives au profil du patient, à son état de santé général et à ses antécédents.

Données physiologiques

La table PHYSICAL regroupe les principales constantes vitales utilisées dans le projet, notamment le poids, la taille, la tension artérielle et la fréquence cardiaque.

Données d'imagerie

La table UCSFFSX7 fournit des mesures quantitatives issues de l'imagerie cérébrale.

Ces variables permettent d'intégrer une dimension anatomique complémentaire à l'analyse.

Données diagnostiques

La table DXSUM contient les informations diagnostiques utilisées pour construire la variable cible du modèle prédictif.

Elle constitue la référence clinique du projet.

2.3 Arbitrages réalisés

La principale difficulté du projet ne résidait pas dans le choix des algorithmes mais dans la sélection des informations réellement utiles parmi plusieurs centaines de variables disponibles.

Nous avons donc adopté une démarche progressive visant à trouver un équilibre entre richesse informationnelle et simplicité d'exploitation.

L'objectif était de construire une solution capable d'apporter une aide à la décision pertinente tout en conservant un niveau élevé d'interprétabilité.

Les choix réalisés ont été guidés par :

- les recommandations médicales ;
- les analyses exploratoires ;
- la disponibilité des données ;
- les contraintes du projet ;
- les performances observées lors des expérimentations.

Cette démarche a permis de réduire progressivement le périmètre tout en conservant les informations les plus pertinentes pour la problématique étudiée.

2.4 Construction du référentiel de données

Une fois les sources identifiées, nous avons entrepris la construction d'un référentiel unique permettant de consolider les informations provenant des différentes tables sélectionnées.

Le rapprochement des données repose sur deux clés communes :

Clé	Description
------------	--------------------

RID	Identifiant unique du patient
-----	-------------------------------

VISCODE	Identifiant de la visite médicale
---------	-----------------------------------

Cette stratégie garantit la cohérence des informations associées à chaque patient tout en préservant la dimension longitudinale des données.

La consolidation des différentes tables constitue une étape essentielle puisqu'elle transforme plusieurs sources indépendantes en un ensemble cohérent exploitable pour les analyses et les modèles prédictifs.

2.5 Stockage et centralisation des données

Une fois les différentes sources consolidées, nous avons mis en place une base PostgreSQL hébergée sur la plateforme Supabase afin de centraliser les données du projet.

Le choix de Supabase résulte d'un arbitrage entre simplicité de mise en œuvre, coût et fonctionnalités. Plusieurs solutions pouvaient être envisagées, notamment une base PostgreSQL locale ou des services cloud tels qu'AWS, Azure ou Google Cloud Platform. Dans le cadre de ce Proof of Concept, Supabase s'est imposé comme une solution adaptée grâce à sa rapidité de déploiement, son accessibilité à distance et son offre gratuite répondant aux besoins du projet.

Cette plateforme permet de stocker les données consolidées issues des traitements préparatoires ainsi que les jeux de données utilisés lors des phases d'analyse et de modélisation.

La mise en place de cette base centralisée facilite la traçabilité des traitements, le partage des données entre les différents composants de la solution et prépare une éventuelle évolution vers une architecture plus industrialisée.

2.6 Contrôle de la qualité des données

Avant d'engager les phases d'analyse et de modélisation, nous avons réalisé une évaluation de la qualité du référentiel de données.

Cette démarche visait à vérifier :

- la complétude des informations ;
- la cohérence des variables ;
- la disponibilité des données nécessaires aux analyses ;
- la présence éventuelle d'anomalies susceptibles d'affecter les résultats.

Une analyse de la complétude des données a notamment été réalisée à l'aide d'une heatmap des valeurs manquantes.

Figure 2.1 – Heatmap des valeurs manquantes (Annexe D)

Cette visualisation a permis d'identifier les variables nécessitant une attention particulière lors des phases ultérieures de préparation des données.

Les traitements détaillés de préparation et d'imputation sont présentés dans le chapitre consacré à la modélisation.

2.7 Architecture de gestion des données

Afin de structurer les traitements et d'assurer la circulation des données entre les différentes composantes du projet, nous avons mis en place un pipeline organisé en plusieurs étapes successives.

Acquisition

Collecte et intégration des données issues du programme ADNI.

Préparation

Nettoyage, harmonisation et consolidation des données.

Stockage

Centralisation des données dans la base PostgreSQL hébergée sur Supabase.

Analyse

Production des indicateurs et réalisation des analyses exploratoires.

Modélisation

Construction, entraînement et évaluation des modèles prédictifs.

Valorisation

Restitution des résultats à travers :

- l'API FastAPI ;
- l'interface Streamlit ;
- les tableaux de bord Power BI.

Cette architecture garantit la traçabilité des traitements et prépare l'évolution future de la solution.

2.8 Conclusion du chapitre

La gestion des données a constitué l'un des principaux enjeux du projet.

Face à un patrimoine de données particulièrement riche et hétérogène, nous avons mis en œuvre une démarche structurée permettant de sélectionner, consolider, centraliser et qualifier les informations nécessaires à la réalisation du Proof of Concept.

La construction du référentiel, le stockage des données dans Supabase ainsi que les contrôles qualité réalisés ont permis de constituer une base de travail fiable et exploitable pour les analyses et les modèles prédictifs.

Ce socle de données constitue désormais le point de départ des analyses décisionnelles présentées dans le chapitre suivant et de l'ensemble des travaux de modélisation qui en découlent.

CHAPITRE 3 – ANALYSE DÉCISIONNELLE DES DONNÉES

3.1 Objectifs de l'analyse

Une fois le référentiel de données constitué, nous avons réalisé une phase d'analyse exploratoire afin de mieux comprendre les caractéristiques de la population étudiée et d'identifier les facteurs les plus fortement associés au risque de maladie d'Alzheimer.

Cette étape poursuit plusieurs objectifs :

- comprendre la structure des données ;
- identifier les variables les plus pertinentes ;
- mettre en évidence les relations existantes entre les différents indicateurs ;
- fournir des éléments d'aide à la décision à l'équipe médicale ;
- orienter les choix de modélisation.

L'analyse exploratoire constitue ainsi une étape intermédiaire essentielle entre la gestion des données et la construction des modèles prédictifs.

3.2 Analyse de la population étudiée

La première analyse a porté sur la répartition des patients selon leur état cognitif.

La base ADNI distingue initialement plusieurs catégories diagnostiques représentant différents stades d'évolution de la maladie.

Pour répondre à l'objectif de détection précoce, nous avons choisi d'opposer :

- les patients cognitivement sains ;
- les patients présentant des signes de déclin cognitif ou de maladie d'Alzheimer.

Cette approche permet de positionner le projet dans une logique de prévention et d'identification précoce plutôt que dans une simple classification clinique.

L'analyse de la distribution des diagnostics montre que le jeu de données couvre une diversité suffisante de profils pour permettre l'entraînement et l'évaluation de modèles prédictifs robustes.

Figure 3.2 – Répartition des diagnostics (ANNEXE D)

3.3 Enseignements issus des évaluations cognitives

Les analyses réalisées mettent rapidement en évidence le rôle central des tests cognitifs dans l'identification des patients à risque.

Les scores issus des évaluations MMSE, ADAS et CDR présentent des différences significatives entre les différents groupes de patients.

Les résultats montrent notamment :

- une diminution progressive du score MMSE lorsque l'état cognitif se dégrade ;
- une augmentation des scores ADAS associée à l'apparition de troubles cognitifs ;
- une progression des scores CDR reflétant l'évolution du niveau de démence.

Ces observations sont cohérentes avec les connaissances médicales actuelles et confirment la pertinence des variables cognitives dans le cadre du projet.

Figure 3.3 – Distribution du score MMSE (*ANNEXE D*)

Figure 3.4 – Distribution du score TOTAL13 (*ANNEXE D*)

Figure 3.5 – Distribution du score CDRSB (*ANNEXE D*)

3.4 Analyse des relations entre les variables

Afin de mieux comprendre les interactions entre les différentes dimensions médicales, nous avons réalisé une étude des corrélations.

Cette analyse permet d'identifier les variables évoluant de manière similaire et de mieux comprendre les mécanismes sous-jacents aux données observées.

La heatmap de corrélation met en évidence plusieurs groupes de variables fortement liées entre elles, notamment au sein des évaluations cognitives.

Ces résultats confirment que certaines dimensions du fonctionnement cognitif sont étroitement associées et qu'elles décrivent des aspects complémentaires de l'état du patient.

Figure 3.9 – Heatmap de corrélation (*ANNEXE D*)

3.5 Variables les plus associées au diagnostic

L'objectif principal de l'analyse exploratoire consiste à identifier les facteurs les plus susceptibles de contribuer à la prédiction du risque Alzheimer.

Les analyses réalisées montrent que plusieurs variables se distinguent particulièrement :

- CDMEMORY ;
- CDRSB ;
- CDGLOBAL ;

- TOTAL13 ;
- TOTSCORE ;
- MMSCORE ;
- CDJUDGE ;
- CDCOMMUN ;
- CDHOME.

Ces résultats soulignent l'importance des fonctions cognitives dans la caractérisation de la maladie.

Ils confirment également l'intérêt d'une approche reposant sur la combinaison de plusieurs dimensions d'évaluation plutôt que sur un indicateur unique.

Figure 3.8 – Variables les plus corrélées avec le diagnostic (ANNEXE D)

3.6 Apport des données physiologiques et IRM

Si les évaluations cognitives apparaissent comme les indicateurs les plus discriminants, les analyses mettent également en évidence l'intérêt des données complémentaires.

Les constantes physiologiques fournissent des informations sur l'état général du patient tandis que les mesures issues de l'imagerie cérébrale apportent une dimension anatomique à l'analyse.

Ces informations ne permettent pas à elles seules d'expliquer le risque Alzheimer mais elles enrichissent la compréhension globale du profil patient et contribuent à améliorer la qualité des modèles prédictifs.

Cette complémentarité justifie leur intégration dans le référentiel de données.

3.7 Création d'indicateurs complémentaires

Les analyses précédentes ont mis en évidence l'intérêt des données physiologiques présentes dans la table PHYSICAL.

Afin d'enrichir davantage l'information disponible et de faciliter son exploitation, nous avons créé plusieurs indicateurs cliniques complémentaires à partir des mesures existantes.

Indice de Masse Corporelle (IMC)

L'Indice de Masse Corporelle a été calculé à partir du poids et de la taille des patients.

Cet indicateur fournit une information synthétique sur l'état nutritionnel et permet de remplacer deux mesures brutes par un indicateur médical largement utilisé dans la pratique clinique.

Ratio tensionnel

Nous avons également construit un ratio tensionnel calculé à partir des pressions systolique et diastolique.

Cet indicateur permet de caractériser plus efficacement l'équilibre cardiovasculaire du patient.

Pression pulsée

Enfin, un indicateur de pression pulsée a été créé à partir de la différence entre la pression systolique et la pression diastolique.

Cette mesure est régulièrement utilisée dans les études portant sur le vieillissement vasculaire et apporte une information complémentaire sur l'état physiologique général du patient.

Ces nouveaux indicateurs illustrent la capacité du projet à transformer des données brutes en informations à valeur ajoutée directement exploitables par les modèles et plus facilement interprétables par les professionnels de santé.

3.8 Principaux enseignements

L'analyse exploratoire a permis de dégager plusieurs enseignements majeurs.

Premièrement, les variables cognitives constituent les facteurs les plus fortement associés au risque Alzheimer.

Deuxièmement, les données physiologiques et les mesures IRM apportent une information complémentaire permettant d'enrichir la compréhension du profil patient.

Troisièmement, la création d'indicateurs synthétiques améliore l'interprétabilité des données et facilite leur exploitation dans un contexte décisionnel.

Ces enseignements ont directement guidé les choix réalisés lors de la conception de la solution prédictive présentée dans le chapitre suivant.

3.9 Conclusion du chapitre

L'analyse décisionnelle des données a permis de transformer un ensemble complexe d'informations médicales en connaissances exploitables.

Au-delà de la simple exploration statistique, cette étape a contribué à identifier les facteurs les plus pertinents pour la détection précoce du risque Alzheimer et à enrichir le référentiel de données par la création d'indicateurs complémentaires.

Les résultats obtenus constituent le socle des travaux de modélisation présentés dans le chapitre suivant.

CHAPITRE 4 – CONCEPTION DE LA SOLUTION PRÉDICTIVE

4.1 Objectifs de la modélisation

À l'issue des phases de gestion des données et d'analyse exploratoire, notre objectif était de concevoir une solution capable d'estimer le risque de maladie d'Alzheimer à partir des informations médicales disponibles.

Cette étape vise à transformer les connaissances acquises lors des analyses précédentes en un outil d'aide à la décision exploitable par les professionnels de santé.

L'objectif n'est pas de remplacer le diagnostic médical mais d'identifier automatiquement des profils présentant des caractéristiques associées à un risque accru de déclin cognitif.

Afin de répondre à ce besoin, plusieurs approches de Machine Learning ont été évaluées et comparées selon des critères de performance, de robustesse et d'interprétabilité.

4.2 Préparation des données pour la modélisation

Avant l'entraînement des modèles, une phase de prétraitement a été réalisée afin de garantir la qualité et la cohérence des données utilisées.

Les analyses présentées au chapitre précédent ont mis en évidence la présence de valeurs manquantes ainsi que de codifications spécifiques propres au programme ADNI.

Dans un premier temps, les valeurs particulières utilisées pour représenter des données non renseignées ou non applicables (notamment -1, -4, 999 et 9999) ont été harmonisées puis converties en valeurs manquantes.

Une stratégie d'imputation a ensuite été mise en œuvre afin de préserver un maximum d'informations :

- les variables numériques ont été complétées à l'aide de la médiane ;
- les variables catégorielles ont été complétées à partir de la modalité la plus fréquente.

Les variables ont ensuite été préparées afin de pouvoir être exploitées par les algorithmes de Machine Learning.

Cette phase constitue une étape essentielle puisqu'elle garantit la qualité des données utilisées pour l'apprentissage et limite les risques de biais liés aux données incomplètes.

4.3 Construction de la variable cible

La table DXSUM fournit les informations diagnostiques utilisées comme référence clinique dans le cadre du projet.

Afin de répondre à l'objectif de détection précoce, nous avons choisi de construire une variable cible binaire.

Les patients cognitivement normaux (CN) ont été regroupés dans une première catégorie tandis que les patients présentant un Mild Cognitive Impairment (MCI) ou un diagnostic Alzheimer (AD) ont été regroupés dans une seconde catégorie.

Cette approche permet de positionner le modèle dans une logique de prévention en identifiant les patients susceptibles de présenter un risque de déclin cognitif, même lorsque la maladie n'est pas encore installée à un stade avancé.

Valeur Signification

0 Patient cognitivement normal (CN)

1 Patient à risque (MCI ou AD)

Ce choix reflète directement le besoin exprimé par l'équipe médicale qui souhaite identifier précocement les profils nécessitant une attention particulière.

4.4 Constitution des jeux d'entraînement et de test

Afin d'évaluer objectivement les performances des modèles, le référentiel de données a été divisé en deux ensembles distincts :

- un jeu d'entraînement représentant 80 % des observations ;
- un jeu de test représentant 20 % des observations.

Cette séparation permet d'évaluer les modèles sur des données jamais observées durant la phase d'apprentissage.

L'utilisation d'un jeu de test indépendant constitue une pratique essentielle pour mesurer la capacité de généralisation des modèles et limiter les risques de surapprentissage.

4.5 Stratégie de comparaison des modèles

Le choix du modèle final n'a pas été réalisé de manière arbitraire.

Plusieurs algorithmes de Machine Learning ont été entraînés puis comparés afin d'identifier la solution la plus adaptée à la problématique étudiée.

Cette démarche comparative permet de sélectionner un modèle sur la base de résultats objectifs plutôt que sur des hypothèses théoriques.

Chaque algorithme a été évalué selon les mêmes jeux de données et les mêmes indicateurs de performance.

L'objectif était d'identifier l'approche offrant le meilleur compromis entre :

- performance prédictive ;
- robustesse ;
- interprétabilité ;
- facilité de déploiement.

4.6 Critères d'évaluation

L'évaluation des modèles repose sur plusieurs indicateurs complémentaires.

Accuracy

L'accuracy mesure la proportion globale de prédictions correctes réalisées par le modèle.

Bien qu'elle fournisse une vision générale des performances, elle ne permet pas à elle seule d'évaluer correctement un modèle dans un contexte médical.

Precision

La précision mesure la proportion de patients réellement à risque parmi ceux identifiés comme tels par le modèle.

Recall

Le rappel mesure la capacité du modèle à détecter correctement les patients présentant effectivement un risque.

Cet indicateur revêt une importance particulière dans le cadre du projet.

En effet, un faux négatif correspond à un patient potentiellement à risque qui ne serait pas identifié par le système.

Dans une logique de détection précoce, ce type d'erreur peut avoir un impact important sur la prise en charge.

F1-Score

Le F1-Score constitue une synthèse entre la précision et le rappel.

Il permet d'obtenir une vision équilibrée des performances du modèle.

ROC-AUC

L'aire sous la courbe ROC (ROC-AUC) mesure la capacité du modèle à distinguer les différentes catégories de patients.

Cet indicateur est particulièrement utile pour comparer plusieurs modèles entre eux.

4.7 Résultats comparatifs

Les différents modèles testés ont été comparés à l'aide des indicateurs présentés précédemment.

Les résultats obtenus montrent que plusieurs approches permettent d'obtenir des performances satisfaisantes. Toutefois, certaines solutions se distinguent par leur capacité à maintenir un bon équilibre entre précision et rappel.

Figure 4.1 – Comparaison des performances des modèles (ANNEXE E)

Cette phase comparative a permis d'objectiver le choix du modèle final et de s'assurer que celui-ci répondait aux exigences définies en début de projet.

4.8 Choix du modèle Random Forest

À l'issue des expérimentations réalisées, le modèle Random Forest a été retenu comme solution principale du Proof of Concept.

Plusieurs éléments justifient ce choix :

- performances globales élevées ;
- bon équilibre entre précision et rappel ;
- robustesse face aux données hétérogènes ;
- capacité à gérer des interactions complexes entre variables ;
- interprétabilité satisfaisante grâce à l'analyse de l'importance des variables.

Ces caractéristiques en font un candidat particulièrement adapté à un projet d'aide à la décision dans le domaine de la santé.

Les métriques détaillées sont présentées en *ANNEXE E*.

4.9 Analyse de l'importance des variables

L'un des avantages du Random Forest réside dans sa capacité à fournir une estimation de l'importance relative des variables utilisées.

Cette analyse permet d'identifier les facteurs ayant le plus contribué aux prédictions.

Les résultats obtenus confirment les observations réalisées lors de l'analyse exploratoire.

Les variables cognitives figurent parmi les plus influentes :

- MMSCORE ;

- CDMEMORY ;
- CDRSB ;
- TOTAL13 ;
- CDGLOBAL ;
- TOTSCORE.

Figure 4.1 – Importance des variables du modèle Random Forest (*ANNEXE G*)

Cette cohérence entre l'analyse exploratoire et les résultats du modèle renforce la confiance dans la pertinence des choix réalisés tout au long du projet.

4.10 Expérimentation Deep Learning sur les données IRM

En complément du modèle principal, une expérimentation basée sur l'apprentissage profond a été réalisée à partir des images IRM disponibles.

Cette approche repose sur l'utilisation d'un réseau de neurones convolutifs (CNN) capable d'extraire automatiquement des caractéristiques visuelles à partir des images cérébrales.

L'objectif de cette expérimentation était d'évaluer la capacité d'une approche fondée exclusivement sur l'imagerie à détecter des signes associés à la maladie d'Alzheimer.

Les résultats obtenus démontrent le potentiel de cette approche mais mettent également en évidence des contraintes importantes :

- volume de données plus limité ;
- temps d'entraînement plus élevé ;
- besoins matériels supérieurs ;
- interprétation plus complexe.

Pour ces raisons, cette expérimentation a été conservée comme piste complémentaire tandis que le Random Forest a été retenu pour le Proof of Concept principal.

L'architecture détaillée du CNN est présentée en *ANNEXE H*.

4.11 Conclusion du chapitre

Les travaux de préparation des données, d'analyse exploratoire et de comparaison des modèles ont permis de concevoir une solution prédictive capable d'estimer le risque de maladie d'Alzheimer à partir d'informations médicales hétérogènes.

L'évaluation comparative des différentes approches a conduit au choix d'un modèle Random Forest offrant un compromis satisfaisant entre performance, robustesse et interprétabilité.

Les résultats obtenus valident la pertinence de la démarche retenue et constituent la base de la solution industrialisée présentée dans le chapitre suivant.

CHAPITRE 5 - INDUSTRIALISATION ET DÉPLOIEMENT DE LA SOLUTION

5.1 Objectifs de l'industrialisation

Une fois le modèle prédictif sélectionné et validé, l'objectif du projet ne se limitait plus à l'obtention de bonnes performances sur un jeu de données de test.

L'enjeu consistait à transformer les travaux d'analyse et de modélisation en une solution opérationnelle capable de produire des prédictions à partir de nouvelles données et de restituer les résultats sous une forme exploitable par les professionnels de santé.

Cette phase d'industrialisation poursuit plusieurs objectifs :

- automatiser le processus de prédiction ;
- faciliter l'accès aux résultats ;
- assurer la reproductibilité des traitements ;
- garantir la cohérence des différents composants de la solution ;
- préparer une éventuelle évolution vers un environnement de production.

L'approche retenue repose sur une architecture modulaire séparant les traitements métier, les services de calcul et les outils de restitution.

5.2 Architecture générale de la solution

L'architecture développée s'appuie sur plusieurs composants complémentaires permettant de couvrir l'ensemble de la chaîne de valorisation des données.

L'utilisateur interagit avec une interface web développée sous Streamlit.

Les données saisies sont ensuite transmises à une API FastAPI qui assure le chargement du modèle et l'exécution des prédictions.

Le résultat est alors retourné à l'interface utilisateur sous une forme directement exploitable.

En parallèle, les analyses exploratoires, les indicateurs métier et les performances du modèle sont valorisés à travers des tableaux de bord Power BI.

Les données préparées et consolidées sont stockées dans une base PostgreSQL hébergée sur Supabase, qui constitue le point central de stockage du projet. Cette base permet de centraliser les données issues des différentes phases de traitement et de faciliter leur exploitation par les différents composants de la solution.

Cette architecture permet de distinguer clairement :

- la couche de données (Supabase PostgreSQL) ;

- la couche de présentation (Streamlit) ;
- la couche métier (FastAPI et Machine Learning) ;
- la couche décisionnelle (Power BI).

Cette séparation facilite la maintenance, l'évolution future de la solution et l'intégration éventuelle de nouveaux composants.

Figure 5.1 – Architecture globale de la solution (Annexe A)

5.3 Choix technologiques

La phase d'industrialisation a nécessité plusieurs arbitrages techniques afin de sélectionner les outils les plus adaptés aux objectifs du projet.

Les choix réalisés ont été guidés par plusieurs critères :

- simplicité de développement ;
- rapidité de mise en œuvre ;
- compatibilité avec l'écosystème Python ;
- facilité de déploiement ;
- maintenabilité de la solution.

Choix de FastAPI

Pour le développement de l'API de prédiction, plusieurs frameworks ont été étudiés, notamment Flask et FastAPI.

Le choix s'est porté sur FastAPI en raison de ses nombreux avantages :

- gestion native du typage Python ;
- validation automatique des données d'entrée ;
- bonnes performances d'exécution ;
- génération automatique d'une documentation interactive Swagger.

Cette documentation facilite les phases de test et simplifie l'intégration de futurs consommateurs de l'API.

Choix de Streamlit

Pour le développement de l'interface utilisateur, nous avons comparé plusieurs solutions destinées aux projets Data Science, notamment Dash et Streamlit.

Streamlit a été retenu pour sa simplicité d'utilisation et sa rapidité de prototypage.

L'outil permet de construire rapidement des interfaces interactives entièrement développées en Python, ce qui a facilité la mise en œuvre du Proof of Concept.

Choix de Docker

La reproductibilité constitue un enjeu important dans les projets de Data Science.

Afin de garantir un fonctionnement identique entre les environnements de développement et de déploiement, nous avons choisi de conteneuriser les différents composants de la solution à l'aide de Docker.

Cette approche permet d'encapsuler le code, les bibliothèques et les dépendances nécessaires au bon fonctionnement des applications.

5.4 Développement de l'API de prédiction

Le modèle retenu a été exposé sous forme de service web grâce au framework FastAPI.

Cette API constitue le point central de communication entre les différents composants de la solution.

Elle assure plusieurs fonctions :

- réception des données saisies par l'utilisateur ;
- validation des informations transmises ;
- chargement du modèle prédictif ;
- exécution de la prédiction ;
- restitution du résultat.

L'utilisation d'une API permet de découpler totalement le modèle de l'interface utilisateur.

Cette architecture favorise la réutilisation du modèle par d'autres applications et facilite les évolutions futures du système.

FastAPI génère automatiquement une documentation interactive Swagger permettant de tester les endpoints et de vérifier le bon fonctionnement du service.

Figure 5.2 – Documentation Swagger de l'API (Annexe J)

5.5 Interface utilisateur Streamlit

Afin de rendre la solution accessible aux utilisateurs non techniques, nous avons développé une interface web à l'aide du framework Streamlit.

L'application permet de saisir les différentes variables utilisées par le modèle :

- scores cognitifs ;
- mesures physiologiques ;
- indicateurs médicaux ;
- variables issues de l'imagerie.

Une fois les informations renseignées, l'utilisateur peut lancer une prédiction directement depuis l'interface.

Le résultat est ensuite affiché sous une forme synthétique permettant une lecture rapide et intuitive.

Cette approche répond à l'objectif principal du projet : fournir un outil d'aide à la décision facilement utilisable par des professionnels de santé.

Figure 5.3 – Interface de prédiction Streamlit (Annexe M)

5.6 Visualisation décisionnelle avec Power BI

Au-delà de la prédiction individuelle, le projet vise également à fournir une vision globale des données et des résultats.

Pour répondre à cet objectif, plusieurs tableaux de bord ont été développés sous Power BI.

Ces tableaux de bord permettent notamment :

- d'explorer les caractéristiques de la population étudiée ;
- d'analyser les facteurs associés au risque Alzheimer ;
- de visualiser les performances des modèles ;
- de suivre les principaux indicateurs du projet.

Power BI complète ainsi l'application de prédiction en apportant une dimension analytique destinée aux utilisateurs métiers.

Figure 5.4 – Tableau de bord Power BI (Annexe L)

5.7 Conteneurisation avec Docker

Afin de garantir la reproductibilité des déploiements, les différents composants de la solution ont été conteneurisés à l'aide de Docker.

Cette approche permet d'encapsuler l'ensemble des dépendances nécessaires à l'exécution des applications.

Chaque composant dispose ainsi d'un environnement maîtrisé et reproductible.

La conteneurisation facilite :

- le partage du projet ;
- les phases de test ;
- les déploiements ;
- la maintenance de la solution.

Docker a également permis de simplifier l'intégration entre l'API FastAPI et l'application Streamlit.

Figure 5.5 – Architecture Docker de la solution (Annexe M)

5.8 Déploiement sur Render

Le déploiement du Proof of Concept a été réalisé sur la plateforme cloud Render.

Cette solution permet d'héberger facilement des applications web développées en Python tout en s'intégrant directement avec GitHub.

Le choix de Render a été motivé par :

- sa simplicité de configuration ;
- sa compatibilité avec Docker ;
- son intégration avec les dépôts Git ;
- la disponibilité d'une offre gratuite adaptée aux phases de prototypage.

L'API FastAPI ainsi que l'application Streamlit ont ainsi été déployées et rendues accessibles à distance.

Cette étape a permis de valider le fonctionnement complet de la chaîne de traitement dans un environnement proche des conditions réelles d'utilisation.

Figure 5.6 – Déploiement sur Render (Annexe M)

5.9 Limites du Proof of Concept

Le projet présenté constitue un Proof of Concept destiné à démontrer la faisabilité technique de la solution.

Certaines fonctionnalités nécessaires à une mise en production n'ont volontairement pas été implémentées.

Parmi les principaux axes d'amélioration figurent :

- l'authentification des utilisateurs ;
- la gestion des droits d'accès ;
- la traçabilité des connexions ;
- la surveillance des performances du modèle ;
- le monitoring du drift des données ;
- l'automatisation du réentraînement ;
- le renforcement des mécanismes de sécurité.

Ces éléments relèvent davantage d'une démarche d'industrialisation avancée et pourront être intégrés dans une version future de la solution.

5.10 Conclusion du chapitre

Cette phase d'industrialisation a permis de transformer un modèle prédictif en une solution complète et exploitable par les utilisateurs.

L'utilisation combinée de FastAPI, Streamlit, Power BI, Docker et Render a permis de construire une architecture cohérente couvrant l'ensemble de la chaîne de valorisation des données.

Les résultats obtenus démontrent la faisabilité technique d'une solution d'aide à la décision reposant sur l'exploitation de données médicales et constituent une base solide pour une éventuelle évolution vers un environnement de production.

CHAPITRE 6 – PILOTAGE ET GESTION DU PROJET

6.1 Gouvernance et organisation du projet

Le développement du Proof of Concept a nécessité la coordination de plusieurs activités couvrant l'ensemble du cycle de valorisation des données :

- compréhension du besoin métier ;
- gestion et préparation des données ;
- analyses exploratoires ;
- conception des modèles prédictifs ;
- industrialisation de la solution ;
- restitution des résultats.

Afin d'assurer une progression maîtrisée du projet et de favoriser la collaboration au sein de l'équipe, nous avons adopté une organisation inspirée du cadre Agile Scrum.

Cette approche nous a permis de structurer les travaux sous forme d'itérations courtes, de suivre régulièrement l'avancement du projet et d'adapter les priorités en fonction des résultats obtenus et des difficultés rencontrées.

L'organisation retenue a également favorisé une implication continue de chaque membre de l'équipe dans les activités techniques, organisationnelles et décisionnelles.

6.2 Répartition des rôles et responsabilités

L'équipe projet était composée de :

- Magalie Césarini ;
- Bruce Vignolles ;
- Assmaa Abdelmoumni.

Chaque membre a participé aux différentes phases du projet, depuis la gestion des données jusqu'au déploiement de la solution.

Dans une logique de montée en compétence collective, les rôles de Scrum Master et de Product Owner ont volontairement alterné à chaque sprint.

Cette organisation a permis à chacun de participer :

- à la gestion du backlog ;
- à la priorisation des besoins ;

- à la coordination des travaux ;
- à la validation des livrables ;
- à la communication autour du projet.

La rotation des responsabilités a renforcé la polyvalence de l'équipe et permis une meilleure compréhension des enjeux globaux du projet.

6.3 Utilisation de Jira pour le pilotage opérationnel

L'ensemble du projet a été piloté à l'aide de Jira, utilisé comme référentiel central de gestion des activités.

Les fonctionnalités exploitées comprenaient :

- la gestion du backlog ;
- la rédaction des User Stories ;
- la planification des sprints ;
- le suivi des tâches ;
- la gestion des anomalies ;
- le suivi de l'avancement.

Chaque besoin fonctionnel a été traduit sous forme de User Story afin de maintenir une vision claire des objectifs à atteindre et de faciliter leur suivi.

Cette formalisation a contribué à améliorer la traçabilité des travaux réalisés et à renforcer la communication au sein de l'équipe.

Figure 6.1 – Backlog Jira (Annexe I)

6.4 Gestion des sprints et suivi de l'avancement

Le projet a été organisé en plusieurs sprints successifs permettant de structurer les développements et de valider progressivement les différentes composantes de la solution.

Chaque sprint comprenait :

- une phase de planification ;
- une répartition des tâches ;
- un suivi régulier de l'avancement ;
- une revue des résultats obtenus.

Cette organisation a permis de valider progressivement :

- la gestion des données ;
- les analyses exploratoires ;
- la modélisation ;
- l'industrialisation ;
- les outils de restitution.

Le suivi de l'avancement a reposé sur plusieurs indicateurs fournis par Jira.

Parmi ceux-ci, le Burndown Chart a permis de visualiser l'évolution de la charge de travail restante au cours des sprints et de mesurer l'écart éventuel entre la planification initiale et la progression réelle du projet.

Figure 6.2 – Burndown Chart (Annexe I)

Le tableau Kanban a également constitué un outil de pilotage quotidien en permettant de suivre l'état des différentes tâches :

- À faire ;
- En cours ;
- En revue ;
- Terminé.

Cette visualisation a facilité la coordination de l'équipe et l'identification rapide des points de blocage.

Figure 6.3 – Workflow Jira et tableau Kanban (Annexe I)

6.5 Gestion des risques

Comme tout projet de valorisation des données, le projet présentait plusieurs facteurs de risque susceptibles d'affecter les délais, la qualité des livrables ou les performances de la solution.

Les principaux risques identifiés concernaient :

- la qualité et la complétude des données ;
- la disponibilité de certaines informations ;
- l'intégration de plusieurs sources hétérogènes ;

- les performances des modèles ;
- les contraintes liées au déploiement.

Une surveillance régulière de ces risques a été réalisée tout au long du projet.

L'approche itérative adoptée a permis d'identifier rapidement les difficultés rencontrées et de mettre en place des actions correctives lorsque cela était nécessaire.

Cette démarche a contribué à sécuriser les différentes phases du projet et à limiter les impacts potentiels sur les livrables.

6.6 Estimation budgétaire du projet

Même si le projet a été réalisé dans le cadre d'un Proof of Concept, une estimation simplifiée des coûts a été réalisée afin d'évaluer les ressources nécessaires à sa mise en œuvre.

Ressources humaines

L'équipe projet était composée de trois membres ayant participé aux différentes phases de réalisation.

Ressource	Charge estimée
Membre équipe projet 1	25 jours
Membre équipe projet 2	25 jours
Membre équipe projet 3	25 jours
Total	75 jours/homme

En considérant un coût journalier moyen de 350 € pour un profil Data junior, le coût théorique des ressources humaines peut être estimé à :

$$75 \text{ jours} \times 350 \text{ €} = 26\,250 \text{ €}$$

Ressources techniques

Outil	Coût utilisé dans le projet
ADNI	Gratuit
Knime	Gratuit
VSCode	Gratuit

Outil	Coût utilisé dans le projet
-------	-----------------------------

Supabase	Gratuit
----------	---------

Python	Gratuit
--------	---------

Jupyter Notebook	Gratuit
------------------	---------

Scikit-Learn	Gratuit
--------------	---------

FastAPI	Gratuit
---------	---------

Streamlit	Gratuit
-----------	---------

Docker	Gratuit
--------	---------

GitHub	Gratuit
--------	---------

Jira	Gratuit
------	---------

Render (offre utilisée)	Gratuit
-------------------------	---------

Power BI Desktop	Gratuit
------------------	---------

L'utilisation d'outils open source et de services gratuits a permis de limiter fortement les coûts d'infrastructure durant la phase de prototypage.

Dans le cadre d'une mise en production, des coûts complémentaires devraient être envisagés pour l'hébergement, la supervision, le partage des tableaux de bord ou encore la gestion des accès utilisateurs.

6.7 Communication et coordination

La réussite du projet a reposé sur une communication régulière entre les membres de l'équipe.

Des échanges fréquents ont permis :

- de partager les avancées ;
- de résoudre les difficultés techniques ;
- d'aligner les décisions prises ;
- de coordonner les travaux réalisés sur les différentes composantes du projet.

Cette communication continue a contribué à maintenir une vision commune des objectifs et à garantir la cohérence globale de la solution développée.

6.8 Contribution aux objectifs métier

Au-delà des aspects techniques, les activités de pilotage ont permis de maintenir un alignement permanent entre les développements réalisés et le besoin exprimé par les professionnels de santé.

Chaque décision prise au cours du projet a été évaluée selon sa capacité à répondre à l'objectif principal : fournir un outil d'aide à la décision permettant d'identifier précocement les patients à risque de maladie d'Alzheimer.

Cette démarche a orienté les arbitrages réalisés en matière de données, de modélisation et d'industrialisation.

6.9 Conclusion du chapitre

Le pilotage du projet a constitué un facteur déterminant dans la réussite du Proof of Concept.

L'utilisation d'une organisation Agile, le recours à Jira pour le suivi opérationnel, la rotation des responsabilités entre les membres de l'équipe et la prise en compte des aspects budgétaires ont permis d'assurer une coordination efficace tout au long des travaux.

Cette gouvernance a favorisé la maîtrise des risques, la qualité des livrables et l'alignement permanent entre les développements réalisés et les attentes des professionnels de santé.

Au-delà de la réalisation technique de la solution, ce projet démontre l'importance d'une démarche de pilotage structurée pour conduire efficacement un projet de valorisation des données dans un contexte médical.

CHAPITRE 7 – COMMUNICATION DES RÉSULTATS, LIMITES ET PERSPECTIVES

7.1 Restitution des résultats aux professionnels de santé

L'un des objectifs majeurs du projet consistait à rendre les résultats exploitables par des professionnels de santé ne disposant pas nécessairement d'une expertise en Data Science.

La valeur d'une solution d'aide à la décision ne repose pas uniquement sur ses performances techniques mais également sur sa capacité à restituer une information compréhensible, interprétable et utilisable dans un contexte métier.

Dans cette optique, nous avons veillé à privilégier des indicateurs clairs et des visualisations facilitant la lecture des résultats.

L'ensemble de la démarche a été conçu afin de permettre aux utilisateurs de comprendre les principaux facteurs associés au risque Alzheimer sans nécessiter de connaissances approfondies en intelligence artificielle.

7.2 Valorisation des résultats

Les résultats du projet sont restitués à travers plusieurs supports complémentaires.

Interface de prédiction

L'application Streamlit permet d'obtenir une estimation du risque Alzheimer à partir des caractéristiques renseignées pour un patient.

L'utilisateur accède à un résultat synthétique facilitant l'interprétation de la prédiction produite par le modèle.

Tableaux de bord Power BI

Les tableaux de bord développés sous Power BI offrent une vision plus globale des données et des résultats obtenus.

Ils permettent notamment :

- d'explorer les caractéristiques de la population étudiée ;
- d'analyser les principaux facteurs associés au risque Alzheimer ;
- de visualiser les performances des modèles ;
- d'illustrer les enseignements issus des analyses exploratoires.

Cette approche favorise une meilleure compréhension des résultats par les parties prenantes du projet.

7.3 Enseignements pour l'équipe médicale

Les analyses réalisées mettent en évidence plusieurs enseignements susceptibles d'intéresser les professionnels de santé.

Les résultats confirment notamment le rôle prépondérant des évaluations cognitives dans l'identification précoce des patients à risque.

Les scores issus des tests MMSE, ADAS et CDR apparaissent comme les variables les plus fortement associées au diagnostic.

Les analyses montrent également que l'intégration de données complémentaires telles que les mesures physiologiques ou les informations issues de l'imagerie cérébrale permet d'enrichir la compréhension globale du profil patient.

Ces observations sont cohérentes avec les connaissances médicales actuelles et renforcent la pertinence de l'approche retenue.

7.4 Limites du projet

Bien que les résultats obtenus soient encourageants, plusieurs limites doivent être prises en compte.

Limites liées aux données

Le projet repose exclusivement sur les données du programme ADNI.

Bien que cette base constitue une référence dans le domaine de la recherche sur la maladie d'Alzheimer, elle ne reflète pas nécessairement l'ensemble des populations rencontrées dans les établissements de santé.

Par ailleurs, certaines variables présentent des niveaux de complétude variables qui peuvent influencer les résultats obtenus.

Limites liées au modèle

Le modèle Random Forest retenu présente de bonnes performances mais ne permet pas d'expliquer individuellement chacune de ses décisions avec le même niveau de transparence qu'une analyse clinique réalisée par un professionnel de santé.

Les résultats produits doivent donc être considérés comme un outil d'aide à la décision et non comme un diagnostic médical.

Limites liées au périmètre du Proof of Concept

Le projet a été réalisé dans le cadre d'un Proof of Concept visant à démontrer la faisabilité technique et fonctionnelle de la solution.

Certaines fonctionnalités nécessaires à une exploitation en production n'ont pas été intégrées :

- gestion avancée des utilisateurs ;
- authentification ;
- traçabilité des accès ;
- surveillance continue du modèle ;
- réentraînement automatisé.

7.5 Perspectives d'évolution

Plusieurs axes d'amélioration peuvent être envisagés afin d'enrichir la solution développée.

Renforcement du patrimoine de données

L'intégration de nouvelles sources de données médicales pourrait permettre d'améliorer la précision des modèles et d'élargir le périmètre fonctionnel de la solution.

Développement des approches Deep Learning

Les premiers travaux réalisés sur les images IRM à l'aide d'un réseau de neurones convolutifs (CNN) ouvrent des perspectives intéressantes.

Une augmentation du volume d'images disponibles pourrait permettre d'améliorer davantage les performances de cette approche.

Mise en production

Une évolution vers un environnement de production nécessiterait la mise en place de plusieurs mécanismes complémentaires :

- authentification des utilisateurs ;
- gestion des droits d'accès ;
- supervision de l'application ;
- surveillance du drift des données ;
- suivi des performances du modèle dans le temps.

Explicabilité de l'intelligence artificielle

L'intégration d'outils d'explicabilité tels que SHAP ou LIME pourrait permettre aux professionnels de santé de mieux comprendre les facteurs ayant influencé les prédictions produites par le modèle.

Cette évolution renforcerait la confiance dans l'utilisation de la solution et faciliterait son adoption dans un contexte médical.

7.6 Apports du projet

Au-delà de la performance du modèle développé, le projet a permis de démontrer la capacité d'une démarche de gestion et de valorisation des données à transformer un volume important d'informations médicales en connaissances exploitables.

Les travaux réalisés ont permis :

- de structurer un patrimoine de données complexe ;
- de produire des indicateurs à valeur ajoutée ;
- de développer une solution prédictive fonctionnelle ;
- de mettre à disposition des outils de restitution adaptés aux utilisateurs métiers.

Cette démarche illustre concrètement la contribution que peuvent apporter les projets Data dans l'amélioration des processus d'analyse et d'aide à la décision.

7.7 Conclusion du chapitre

La communication des résultats constitue une étape essentielle dans tout projet de valorisation des données.

Au-delà de la qualité technique des modèles développés, la réussite d'une solution d'aide à la décision dépend de sa capacité à produire des informations compréhensibles et exploitables par les utilisateurs finaux.

Les résultats obtenus démontrent la faisabilité d'une approche combinant gestion des données, intelligence artificielle et outils de visualisation pour accompagner les professionnels de santé dans l'identification précoce des patients à risque de maladie d'Alzheimer.

Les limites identifiées et les perspectives présentées ouvrent la voie à de futures évolutions permettant d'enrichir progressivement la solution développée.

CONCLUSION GÉNÉRALE

La maladie d'Alzheimer constitue aujourd'hui un enjeu majeur de santé publique. Face à l'augmentation du nombre de personnes concernées et à la complexité des mécanismes impliqués dans son développement, les professionnels de santé doivent s'appuyer sur un volume croissant d'informations médicales afin d'orienter leurs décisions.

Dans ce contexte, l'objectif de notre projet était d'étudier la faisabilité d'une solution d'aide à la décision capable d'exploiter des données médicales hétérogènes afin d'identifier précocement les patients présentant un risque de développer la maladie d'Alzheimer.

Pour répondre à ce besoin, nous avons mis en œuvre une démarche complète de gestion et de valorisation des données reposant sur les informations issues du programme ADNI.

Les travaux réalisés ont permis :

- d'identifier et sélectionner les sources de données les plus pertinentes ;
- de construire un référentiel de données cohérent à partir de plusieurs tables médicales ;
- d'évaluer et améliorer la qualité des données ;
- de produire des analyses permettant de mieux comprendre les facteurs associés au risque Alzheimer ;
- de développer une solution prédictive fondée sur des techniques de Machine Learning ;
- d'industrialiser cette solution sous la forme d'une application accessible via une interface web et des tableaux de bord décisionnels.

Les résultats obtenus démontrent la pertinence d'une approche combinant gestion des données, intelligence artificielle et outils de visualisation dans un contexte médical.

Les analyses exploratoires ont confirmé le rôle prépondérant des évaluations cognitives dans la caractérisation du risque Alzheimer tout en mettant en évidence l'intérêt des données physiologiques et de certaines mesures issues de l'imagerie cérébrale.

La comparaison des différents modèles a conduit au choix d'un Random Forest offrant un compromis satisfaisant entre performance, robustesse et interprétabilité. En complément, une expérimentation basée sur un réseau de neurones convolutifs (CNN) appliqué aux images IRM a permis d'explorer le potentiel des approches Deep Learning dans ce domaine.

Au-delà des performances obtenues, ce projet a permis de démontrer qu'une démarche structurée de gestion des données peut transformer un patrimoine informationnel complexe en connaissances directement exploitables par les professionnels de santé.

La réalisation de ce Proof of Concept a également mis en évidence plusieurs perspectives d'évolution, notamment l'intégration de nouvelles sources de données, le renforcement des mécanismes d'explicabilité des modèles, l'amélioration des approches Deep Learning et la mise en place d'une architecture adaptée à un contexte de production.

Enfin, ce projet illustre la contribution que peuvent apporter les métiers de la donnée dans le domaine de la santé en facilitant l'exploitation de volumes importants d'informations médicales et en fournissant des outils capables d'accompagner les professionnels dans leurs prises de décision.

Ainsi, au-delà de la réalisation technique de la solution, cette démarche démontre l'intérêt stratégique de la valorisation des données comme levier d'innovation et d'amélioration des pratiques dans le secteur de la santé.

REMERCIEMENTS

La réalisation de ce projet a mobilisé de nombreuses compétences en gestion des données, analyse statistique, intelligence artificielle et développement applicatif. Au-delà des aspects techniques, cette expérience a constitué une opportunité de mettre en pratique une démarche complète de valorisation des données appliquée à un enjeu majeur de santé publique.

Nous tenons à remercier l'ensemble des personnes ayant contribué, directement ou indirectement, à la réalisation de ce projet.

Nos remerciements s'adressent tout particulièrement aux équipes pédagogiques et aux intervenants qui nous ont accompagnés tout au long de ce parcours. Leurs conseils, leur expertise et leurs retours constructifs ont contribué à enrichir notre réflexion et à faire progresser notre démarche.

Nous remercions également les chercheurs et organismes impliqués dans le programme ADNI (Alzheimer's Disease Neuroimaging Initiative), dont les travaux et la mise à disposition des données ont rendu possible la réalisation de ce projet. Cette initiative constitue aujourd'hui une référence internationale dans l'étude des maladies neurodégénératives et représente une ressource précieuse pour la recherche et l'innovation en santé.

Nous souhaitons également remercier les membres de notre équipe projet pour leur implication, leur esprit de collaboration et leur engagement tout au long des différentes phases de réalisation. La complémentarité des compétences et le partage des responsabilités ont largement contribué à la réussite du projet.

Enfin, nous adressons nos remerciements à l'ensemble des professionnels de santé dont les besoins et les enjeux métiers ont guidé notre réflexion. Leur expertise constitue un élément essentiel pour donner du sens à l'exploitation des données et orienter les travaux vers des solutions concrètes d'aide à la décision.

Ce projet illustre la richesse de la collaboration entre les domaines de la santé et de la science des données, et démontre le potentiel de la valorisation des données au service de l'amélioration des pratiques et de l'accompagnement des professionnels.

RÉSUMÉ EXÉCUTIF

La maladie d'Alzheimer représente aujourd'hui l'un des principaux défis de santé publique liés au vieillissement de la population. L'identification précoce des patients à risque constitue un enjeu majeur pour les professionnels de santé, mais demeure complexe en raison de la diversité et du volume des informations médicales à analyser.

Dans ce contexte, notre équipe a développé un Proof of Concept (POC) visant à étudier la faisabilité d'une solution d'aide à la décision reposant sur l'exploitation de données médicales issues du programme ADNI (Alzheimer's Disease Neuroimaging Initiative).

Le projet s'inscrit dans une démarche complète de gestion et de valorisation des données. Une première phase a consisté à analyser le patrimoine de données disponible puis à sélectionner les sources les plus pertinentes au regard du besoin exprimé par les professionnels de santé. Dix tables couvrant les dimensions cognitives, physiologiques, médicales, familiales et anatomiques ont été retenues afin de constituer un référentiel de données cohérent.

Une attention particulière a été portée à la qualité des données, notamment à travers l'analyse de la complétude des informations, le traitement des valeurs manquantes et l'harmonisation des codifications spécifiques utilisées dans les données ADNI.

Les analyses exploratoires ont permis d'identifier les principaux facteurs associés au risque de maladie d'Alzheimer. Les résultats confirment le rôle prépondérant des évaluations cognitives telles que MMSE, ADAS et CDR, tout en mettant en évidence l'intérêt de certaines données physiologiques et issues de l'imagerie cérébrale. Des indicateurs complémentaires ont également été créés à partir des constantes vitales afin d'enrichir l'information disponible.

Plusieurs modèles de Machine Learning ont ensuite été développés et comparés. Cette démarche a conduit à la sélection d'un modèle Random Forest offrant un compromis satisfaisant entre performance, robustesse et interprétabilité. Une expérimentation complémentaire basée sur un réseau de neurones convolutifs (CNN) appliqué aux images IRM a également été réalisée afin d'explorer le potentiel des approches Deep Learning.

Enfin, la solution a été industrialisée sous la forme d'une architecture intégrant FastAPI, Streamlit, Power BI, Docker et Render. Cette architecture permet de proposer une interface de prédiction, des tableaux de bord décisionnels et une API de calcul accessibles aux utilisateurs.

Les résultats obtenus démontrent la faisabilité d'une solution d'aide à la décision capable de valoriser des données médicales hétérogènes afin d'accompagner les professionnels de santé dans l'identification précoce des patients à risque de maladie d'Alzheimer. Ils mettent également en évidence le rôle stratégique de la gestion des données et de l'intelligence artificielle dans le développement d'outils innovants au service de la santé.

LISTE DES ACRONYMES

Acronyme Définition

ADNI	Alzheimer's Disease Neuroimaging Initiative
AD	Alzheimer Disease
MCI	Mild Cognitive Impairment
MMSE	Mini Mental State Examination
ADAS	Alzheimer's Disease Assessment Scale
CDR	Clinical Dementia Rating
CNN	Convolutional Neural Network
API	Application Programming Interface
POC	Proof of Concept
IRM	Imagerie par Résonance Magnétique
PIA	Analyse d'Impact relative à la Protection des Données
RGPD	Règlement Général sur la Protection des Données

ANNEXES

Annexe A – Architecture globale de la solution

Annexe B – Description détaillée des tables ADNI

Annexe C – Dictionnaire des variables retenues

Annexe D – Analyse exploratoire des données

- Heatmap des valeurs manquantes
- Répartition des diagnostics
- MMSE
- TOTAL13
- CDRSB
- Heatmap de corrélation
- Variables corrélées

Annexe E – Comparaison des modèles

Annexe F – Matrices de confusion

Annexe G – Importance des variables

Annexe H – Architecture CNN

Annexe I – Captures Jira

Annexe J – Documentation API

Annexe K – Rapport PIA

Annexe L – Captures Power BI

Annexe M – Déploiement Docker et Render