

DÉTECTION PRÉCOCE DE LA MALADIE D'ALZHEIMER PAR MACHINE LEARNING ET DEEP LEARNING À PARTIR DES DONNÉES ADNI

RNCP 35288 – Niveau 6 (Bac+4)

Projet réalisé par

- Bruce VIGNOLLES
- Assmaa ABDELMOUMNI
- Magalie CESARINI

Formation Concepteur Développeur en Science des Données – M2i Formation

RÉSUMÉ EXÉCUTIF

La maladie d'Alzheimer constitue aujourd'hui l'une des principales causes de dépendance chez les personnes âgées. Son caractère neurodégénératif progressif rend particulièrement importante l'identification précoce des signes cliniques annonciateurs de la maladie afin d'améliorer la prise en charge des patients et de ralentir l'évolution des symptômes.

Dans ce contexte, le projet présenté vise à exploiter les données médicales issues de la base de recherche internationale ADNI (Alzheimer's Disease Neuroimaging Initiative) afin de développer une solution d'aide à la détection précoce du risque de maladie d'Alzheimer.

Le projet repose sur la mise en œuvre d'une chaîne complète de traitement de données intégrant la collecte, la préparation, l'analyse exploratoire, la modélisation prédictive et l'industrialisation des résultats. Les données utilisées proviennent de dix tables ADNI regroupant des informations démographiques, cognitives, médicales et biologiques concernant plusieurs milliers de patients suivis longitudinalement.

Une attention particulière a été portée à la préparation des données. L'un des principaux défis a consisté à réduire plusieurs centaines de variables médicales à un ensemble restreint de variables pertinentes permettant de construire des modèles performants tout en conservant leur interprétabilité clinique.

Plusieurs algorithmes de Machine Learning ont été évalués, notamment Random Forest, Gradient Boosting et un modèle Keras. Les performances obtenues ont montré des résultats très satisfaisants avec un F1-score supérieur à 91 %, permettant de sélectionner le modèle Random Forest comme solution de référence.

En complément, une expérimentation Deep Learning basée sur l'analyse d'images IRM cérébrales a été menée afin d'étudier l'apport potentiel des réseaux de neurones convolutifs dans la détection de marqueurs associés à la maladie.

Enfin, l'ensemble de la solution a été industrialisé au travers d'une architecture moderne reposant sur Python, Supabase, FastAPI, Streamlit, Docker, Render et Power BI, permettant la mise à disposition d'un service de prédiction accessible aux utilisateurs finaux.

INTRODUCTION GÉNÉRALE

Les maladies neurodégénératives représentent aujourd'hui un enjeu majeur de santé publique à l'échelle mondiale. Parmi elles, la maladie d'Alzheimer est la forme de démence la plus fréquente et touche plusieurs dizaines de millions de personnes dans le monde.

La progression lente et souvent silencieuse de la maladie rend son diagnostic particulièrement complexe lors des phases précoces. Pourtant, une détection anticipée permet d'améliorer significativement le suivi médical des patients, de mettre en place des stratégies thérapeutiques adaptées et d'accompagner plus efficacement les familles concernées.

Les avancées récentes dans le domaine de la science des données et de l'intelligence artificielle ouvrent de nouvelles perspectives pour l'analyse des données médicales complexes. Les algorithmes de Machine Learning sont désormais capables d'identifier des relations difficilement détectables par les méthodes statistiques traditionnelles et constituent des outils prometteurs pour l'aide à la décision médicale.

Le présent projet s'inscrit dans cette dynamique en exploitant les données de la base ADNI, référence mondiale dans la recherche sur la maladie d'Alzheimer. L'objectif consiste à construire une solution capable d'estimer le risque de développement de la maladie à partir d'indicateurs cliniques, cognitifs et biologiques collectés lors du suivi des patients.

Au-delà de la modélisation prédictive, ce projet vise également à démontrer la capacité à concevoir une solution complète répondant aux exigences du métier de Concepteur Développeur en Science des Données. L'ensemble du cycle de vie de la donnée est ainsi couvert, depuis son acquisition jusqu'à sa restitution auprès des utilisateurs.

Ce rapport présente successivement le contexte du projet, les données exploitées, les analyses réalisées, les modèles développés, les choix d'industrialisation ainsi que les méthodes de pilotage mises en œuvre tout au long du projet.

CHAPITRE 1 – PRÉSENTATION DU PROJET

Annexes complémentaires

- ANNEXE A1 – FICHE PROJET

1.1 Contexte et origine du projet

La maladie d'Alzheimer est une pathologie neurodégénérative caractérisée par une détérioration progressive des fonctions cognitives. Les premiers symptômes peuvent apparaître plusieurs années avant le diagnostic clinique officiel, ce qui rend la détection précoce particulièrement stratégique.

Dans le domaine médical, les professionnels disposent aujourd'hui d'un volume considérable de données issues de tests cognitifs, d'examens biologiques et d'imagerie médicale. Cependant, l'exploitation simultanée de ces informations demeure complexe en raison de leur diversité et de leur volume.

La science des données offre la possibilité d'analyser ces informations de manière automatisée afin d'identifier des schémas prédictifs invisibles à l'œil humain.

C'est dans cette perspective que le projet de détection précoce de la maladie d'Alzheimer a été initié.

Le projet s'appuie sur les données issues du programme ADNI (Alzheimer's Disease Neuroimaging Initiative), l'une des plus importantes bases de données mondiales dédiées à la recherche sur les maladies neurodégénératives.

1.2 Problématique

Les données médicales disponibles contiennent de nombreuses informations susceptibles de refléter l'apparition progressive de troubles cognitifs.

Cependant, plusieurs difficultés rendent leur exploitation complexe :

- grand volume de données ;
- diversité des sources d'information ;
- données longitudinales collectées sur plusieurs années ;
- nombreuses valeurs manquantes ;
- présence de variables fortement corrélées ;
- nécessité de conserver une interprétabilité médicale.

La problématique centrale du projet est donc la suivante :

Comment exploiter les données cliniques, cognitives et biologiques issues de la base ADNI afin de détecter précocement le risque de maladie d'Alzheimer grâce aux techniques de Machine Learning tout en garantissant la reproductibilité et l'industrialisation du processus de prédiction ?

1.3 Objectifs du projet

L'objectif principal du projet consiste à développer un système d'aide à la détection précoce de la maladie d'Alzheimer à partir des données ADNI.

Pour atteindre cet objectif, plusieurs objectifs intermédiaires ont été définis :

- collecter et intégrer les données ADNI ;
- préparer et nettoyer les données ;
- identifier les variables les plus pertinentes ;
- développer plusieurs modèles prédictifs ;
- comparer les performances obtenues ;
- industrialiser la solution ;
- mettre à disposition une interface utilisateur accessible ;
- restituer les résultats sous forme de tableaux de bord décisionnels.

1.4 Livrables réalisés

Les principaux livrables produits dans le cadre du projet sont :

Données

- intégration de 10 tables ADNI ;
- constitution d'un Data Lake sur Supabase ;
- pipelines de préparation automatisés.

Analyse

- analyse exploratoire des données ;
- étude des corrélations ;
- visualisation des facteurs de risque.

Machine Learning

- entraînement et comparaison de plusieurs modèles ;
- sélection automatique du meilleur modèle ;
- sauvegarde des artefacts.

Deep Learning

- expérimentation CNN sur images IRM ;
- analyse comparative des résultats.

Industrialisation

- API FastAPI ;
- interface Streamlit ;
- conteneurisation Docker ;
- déploiement sur Render ;
- intégration Power BI.

1.5 Indicateurs de performance

L'évaluation du projet repose principalement sur les métriques de classification suivantes :

- Accuracy ;
- Precision ;
- Recall ;
- F1-score.

Les résultats obtenus montrent des performances élevées :

Modèle	F1-score
Random Forest	91,96 %
Gradient Boosting	91,88 %
Keras Classifier	91,56 %

Le modèle Random Forest a été retenu comme modèle de référence en raison de son excellent compromis entre performance, robustesse et interprétabilité.

1.6 Principales difficultés rencontrées

La difficulté majeure du projet réside dans la gestion de la complexité des données ADNI.

Les données initiales comportaient plusieurs centaines de variables réparties sur de nombreuses tables distinctes. Une partie importante du travail a consisté à identifier les variables réellement utiles à la prédiction tout en limitant les risques de surapprentissage.

Cette étape a nécessité :

- l'analyse des variables ;
- le traitement des valeurs manquantes ;
- la suppression des variables redondantes ;
- la validation des choix par expérimentation.

Cette démarche a permis de réduire significativement la dimension du jeu de données tout en conservant les informations médicales les plus pertinentes pour la prédiction.

1.7 Structure du rapport

Le présent rapport est organisé selon les principales étapes du cycle de vie d'un projet Data Science.

Le chapitre 2 présente la collecte, la préparation et le stockage des données.

Le chapitre 3 détaille les analyses exploratoires et les visualisations réalisées.

Le chapitre 4 décrit la conception et l'évaluation des modèles de Machine Learning.

Le chapitre 5 présente l'expérimentation Deep Learning menée sur les images IRM.

Le chapitre 6 expose l'industrialisation et le déploiement de la solution.

Le chapitre 7 traite du pilotage du projet, de la communication et de la gouvernance.

Enfin, le chapitre 8 présente la conclusion générale ainsi que les perspectives d'évolution du projet.

CHAPITRE 2 – COLLECTE, PRÉPARATION ET STOCKAGE DES DONNÉES (BLOC 1)

Annexes complémentaires

- ANNEXE A – ARCHITECTURE GLOBALE DE LA SOLUTION
- ANNEXE B – DESCRIPTION DES TABLES ADNI
- ANNEXE C – DICTIONNAIRE DES VARIABLES RETENUES

2.1 Introduction et enjeux

Le Bloc 1 constitue le socle fondamental du projet de détection précoce de la maladie d'Alzheimer. Avant toute phase de modélisation ou d'analyse prédictive, il est indispensable de disposer d'un jeu de données fiable, cohérent et exploitable.

Dans le domaine médical, les données sont généralement dispersées dans plusieurs systèmes, collectées à différentes périodes et stockées sous des formats variés. Cette complexité est particulièrement présente dans la base ADNI (Alzheimer's Disease Neuroimaging Initiative), qui regroupe plusieurs centaines de variables issues d'examens cliniques, cognitifs, biologiques et d'imagerie médicale.

L'objectif de ce premier bloc consiste à transformer ces données brutes en un socle informationnel structuré et exploitable pour les analyses ultérieures.

Cette étape comprend :

- l'identification des sources pertinentes ;
- la sélection des tables utiles au projet ;
- l'intégration des données ;
- le nettoyage ;
- la gestion des valeurs manquantes ;
- la création d'un environnement de stockage centralisé ;
- la préparation des données pour les modèles de Machine Learning.

La qualité de cette phase conditionne directement les performances des modèles développés par la suite. Un modèle performant ne peut être obtenu que si les données utilisées sont fiables, cohérentes et correctement préparées.

2.2 Présentation de la base ADNI

2.2.1 Le programme ADNI

L'Alzheimer's Disease Neuroimaging Initiative (ADNI) est un programme international de recherche lancé en 2004 ayant pour objectif de mieux comprendre les mécanismes de développement de la maladie d'Alzheimer.

Cette initiative regroupe plusieurs centres hospitaliers, laboratoires de recherche et institutions universitaires à travers le monde.

Les données ADNI sont devenues une référence internationale dans la recherche sur les maladies neurodégénératives et sont largement utilisées dans les travaux académiques relatifs au Machine Learning médical.

L'un des principaux avantages de cette base réside dans son suivi longitudinal. Chaque patient est observé sur plusieurs années, permettant d'étudier l'évolution progressive des troubles cognitifs.

Les données mises à disposition comprennent notamment :

- données démographiques ;
- examens cognitifs ;
- diagnostics médicaux ;
- mesures physiologiques ;
- biomarqueurs ;
- imagerie cérébrale IRM ;
- informations médicales historiques ;
- antécédents familiaux.

Cette richesse informationnelle constitue un terrain particulièrement favorable à la construction de modèles prédictifs.

2.2.2 Sélection des tables ADNI

La base ADNI contient plusieurs dizaines de tables. Afin de conserver un périmètre cohérent avec les objectifs du projet, une sélection a été réalisée.

Les dix tables retenues sont les suivantes :

Table	Description
PTDEMOG	Données démographiques
MMSE	Tests cognitifs MMSE

Table	Description
ADAS	Évaluation neuropsychologique
CDR	Évaluation du niveau de démence
PHYSICAL	Données physiologiques
UCSFFSX7	Biomarqueurs
FAMHXP	Antécédents familiaux
MEDHIST	Antécédents médicaux
INITHEALTH	État de santé initial
DXSUM	Diagnostics médicaux

Ces tables ont été sélectionnées pour leur complémentarité et leur pertinence clinique dans le contexte de la détection précoce de la maladie d'Alzheimer.

2.3 Architecture de collecte et d'intégration

2.3.1 Architecture globale

L'architecture mise en œuvre vise à automatiser le traitement des données tout en garantissant leur traçabilité.

Le flux de traitement est organisé selon les étapes suivantes :

ADNI → Python / KNIME → Supabase → Préprocessing → Machine Learning → API FastAPI → Streamlit → Power BI → Render

Cette architecture permet de séparer clairement les responsabilités entre les différents composants du système.

2.3.2 Utilisation de Python

Python constitue le langage principal utilisé pour le traitement des données.

Les bibliothèques suivantes ont été mobilisées :

- Pandas ;
- NumPy ;
- Scikit-Learn ;
- Matplotlib ;

- Seaborn ;
- TensorFlow ;
- Joblib.

Python est utilisé pour :

- l'import des données ;
- le nettoyage ;
- les transformations ;
- l'analyse exploratoire ;
- l'entraînement des modèles ;
- la génération des artefacts.

L'ensemble des traitements est reproductible grâce à l'utilisation de notebooks et de scripts versionnés sous GitHub.

2.3.3 Utilisation de KNIME

KNIME a été utilisé lors des premières phases d'intégration afin de :

- visualiser les flux de données ;
- réaliser les premières jointures ;
- vérifier la cohérence des données ;
- reproduire certaines opérations ETL.

L'utilisation conjointe de Python et KNIME a permis de combiner la flexibilité du code avec la lisibilité d'une approche visuelle.

2.4 Modélisation des données

2.4.1 Clés de jointure

Les différentes tables ADNI ne peuvent être exploitées indépendamment.

Deux clés principales ont été utilisées :

RID

Le RID (Research Identifier) représente l'identifiant unique du patient.

VISCODE

Le VISCODE représente la visite médicale associée à l'enregistrement.

L'utilisation simultanée de RID et VISCODE permet de conserver la cohérence temporelle des observations.

Cette approche évite notamment les erreurs de rapprochement entre plusieurs visites d'un même patient.

2.4.2 Gestion des doublons

Une attention particulière a été portée à l'identification des doublons.

Les contrôles réalisés ont permis de :

- détecter les enregistrements redondants ;
- supprimer les lignes dupliquées ;
- vérifier l'unicité des couples RID/VISCODE.

Cette étape était essentielle pour éviter de biaiser les modèles prédictifs.

2.5 Nettoyage et préparation des données

2.5.1 Analyse de la qualité des données

Les données ADNI présentent plusieurs particularités :

- valeurs manquantes ;
- données incohérentes ;
- codifications spécifiques ;
- variables fortement corrélées.

Une phase approfondie d'analyse de qualité a donc été réalisée avant toute modélisation.

2.5.2 Gestion des valeurs spécifiques ADNI

Plusieurs codes particuliers sont utilisés dans ADNI :

Valeur Signification

-1 Donnée absente

Valeur Signification

-4 Donnée non applicable

999 Valeur inconnue

9999 Valeur manquante

Ces valeurs ne peuvent être interprétées comme des données numériques réelles.

Elles ont donc été converties en valeurs manquantes (NaN) avant les traitements statistiques.

Cette étape était indispensable afin d'éviter l'introduction de biais dans les modèles.

2.5.3 Gestion des valeurs manquantes

L'analyse exploratoire a mis en évidence la présence de nombreuses données incomplètes.

Plusieurs stratégies ont été utilisées :

- suppression des colonnes trop incomplètes ;
- suppression des observations inutilisables ;
- conservation des variables médicalement pertinentes.

L'objectif était de conserver un maximum d'informations tout en garantissant la qualité du jeu de données final.

2.6 Réduction de la dimension

L'un des principaux défis du projet résidait dans le nombre important de variables disponibles.

Après fusion des différentes tables, plusieurs centaines de variables étaient disponibles.

Une utilisation directe de l'ensemble des variables aurait présenté plusieurs risques :

- surapprentissage ;
- augmentation du temps de calcul ;
- baisse de l'interprétabilité ;
- complexification du déploiement.

Une démarche progressive de sélection des variables a donc été mise en œuvre.

Cette démarche repose sur :

- l'expertise métier ;
- l'analyse statistique ;
- l'analyse de corrélation ;
- les performances des modèles.

Cette phase a permis de réduire considérablement le nombre de variables tout en conservant les informations les plus pertinentes.

2.7 Stockage et centralisation des données

2.7.1 Choix de Supabase

Le stockage centralisé des données a été réalisé sur Supabase.

Cette solution a été retenue pour plusieurs raisons :

- compatibilité PostgreSQL ;
- simplicité de mise en œuvre ;
- accès cloud ;
- sécurité ;
- intégration avec Python.

Supabase joue le rôle de Data Lake du projet.

Les jeux de données préparés sont stockés sous forme de tables dédiées permettant leur réutilisation lors des phases de modélisation.

2.7.2 Organisation des données

Les principales tables créées permettent de stocker :

- données d'entraînement ;
- données de test ;
- variables cibles ;
- données préparées.

Cette organisation facilite :

- la traçabilité ;
- la reproductibilité ;

- l'industrialisation du pipeline.

2.8 Bilan du Bloc 1

Le travail réalisé dans le cadre de ce premier bloc a permis de transformer un ensemble complexe de données médicales hétérogènes en un socle de données cohérent et exploitable.

Les principales réalisations sont :

- sélection de dix tables ADNI pertinentes ;
- fusion des données via RID et VISCODE ;
- nettoyage et traitement des valeurs spécifiques ;
- gestion des données manquantes ;
- réduction du nombre de variables ;
- création d'un environnement centralisé sous Supabase ;
- préparation des données pour les modèles de Machine Learning.

Cette étape constitue le fondement de l'ensemble du projet. La qualité des traitements réalisés garantit la fiabilité des analyses exploratoires et des modèles prédictifs présentés dans les chapitres suivants.

Le chapitre suivant présentera l'analyse exploratoire des données ainsi que les visualisations ayant permis d'identifier les variables les plus influentes dans la détection précoce de la maladie d'Alzheimer.

CHAPITRE 3 – ANALYSE EXPLORATOIRE ET VISUALISATION DES DONNÉES (BLOC 2)

Annexes complémentaires

- ANNEXE D – ANALYSE EXPLORATOIRE DES DONNÉES

3.1 Introduction et objectifs

Après la phase de collecte, d'intégration et de préparation des données présentée dans le chapitre précédent, une étape essentielle du projet consiste à analyser le contenu du jeu de données afin d'en comprendre les caractéristiques principales.

Cette phase d'Analyse Exploratoire des Données (Exploratory Data Analysis – EDA) a pour objectif d'explorer les données avant la modélisation afin d'identifier les tendances générales, les anomalies, les relations entre variables et les facteurs susceptibles d'influencer le diagnostic de la maladie d'Alzheimer.

L'EDA constitue une étape fondamentale dans tout projet de Data Science. Elle permet de transformer un ensemble de données brutes en connaissances exploitables pour guider les choix de modélisation.

Dans le cadre du projet, cette phase poursuit plusieurs objectifs :

- comprendre la structure du jeu de données ;
- identifier les distributions des variables ;
- analyser les déséquilibres éventuels ;
- détecter les corrélations significatives ;
- identifier les variables les plus discriminantes ;
- préparer la sélection des variables pour le Machine Learning ;
- produire des visualisations compréhensibles pour les parties prenantes.

Les résultats obtenus lors de cette étape ont joué un rôle majeur dans les choix méthodologiques réalisés lors de la construction des modèles prédictifs.

3.2 Présentation du jeu de données analysé

Après fusion des différentes tables ADNI, le jeu de données consolidé regroupe plusieurs milliers d'observations correspondant à des patients suivis dans le cadre du programme ADNI.

Chaque ligne représente une observation associée à un patient lors d'une visite spécifique identifiée par le couple :

- RID (Research Identifier)

- VISCODE (code de visite)

Les données disponibles couvrent plusieurs dimensions complémentaires :

Informations démographiques

- sexe ;
- niveau d'éducation ;
- situation familiale ;
- caractéristiques générales du patient.

Tests cognitifs

- MMSE ;
- ADAS ;
- CDR.

Données physiologiques

- poids ;
- taille ;
- tension artérielle ;
- fréquence cardiaque.

Antécédents médicaux

- pathologies associées ;
- traitements ;
- historique médical.

Antécédents familiaux

- présence de cas de démence dans la famille ;
- facteurs de risque héréditaires.

Biomarqueurs

- variables issues des examens spécialisés ;
- mesures biologiques associées aux fonctions cognitives.

Cette diversité de données permet d'obtenir une vision relativement complète du profil médical de chaque patient.

3.3 Analyse de la variable cible

L'une des premières étapes de l'analyse consiste à étudier la variable cible utilisée pour l'entraînement des modèles.

Le diagnostic final est issu de la table DXSUM et permet de distinguer plusieurs états cognitifs :

- Patient sain (CN – Cognitively Normal)
- Trouble Cognitif Léger (MCI – Mild Cognitive Impairment)
- Maladie d'Alzheimer (AD)

Cette variable constitue la cible des modèles prédictifs.

L'analyse de sa distribution a permis de vérifier l'équilibre des classes avant l'entraînement.

Une visualisation sous forme d'histogramme a montré que certaines catégories étaient davantage représentées que d'autres.

Cette observation est importante car un déséquilibre trop marqué peut conduire les algorithmes à privilégier les classes majoritaires.

Les analyses réalisées ont permis d'identifier cette problématique dès les premières phases du projet et d'en tenir compte lors de l'évaluation des modèles.

3.4 Analyse descriptive des variables

3.4.1 Statistiques descriptives

Les principales variables numériques ont fait l'objet d'une analyse statistique détaillée.

Pour chaque variable ont été calculés :

- moyenne ;
- médiane ;
- écart-type ;
- minimum ;
- maximum ;
- quartiles.

Cette première exploration permet d'obtenir une vision globale du comportement des données.

Les résultats montrent une forte variabilité entre certaines variables cognitives, traduisant la diversité des profils patients présents dans ADNI.

3.4.2 Distribution des scores cognitifs

Une attention particulière a été portée aux tests cognitifs, qui constituent les variables les plus directement liées à la détection de la maladie.

MMSE

Le Mini Mental State Examination (MMSE) mesure les capacités cognitives générales du patient.

Les distributions observées montrent que les patients diagnostiqués Alzheimer présentent généralement des scores significativement plus faibles que les patients sains.

Cette différence confirme l'importance de cette variable dans le processus de prédiction.

ADAS

Le score ADAS (Alzheimer's Disease Assessment Scale) fournit une évaluation plus fine des troubles cognitifs.

L'analyse des distributions met en évidence une augmentation progressive du score chez les patients présentant une dégradation cognitive.

CDR

Le Clinical Dementia Rating permet d'évaluer le niveau de sévérité de la démence.

Les résultats montrent une corrélation forte entre les valeurs élevées du CDR et les diagnostics Alzheimer.

3.5 Analyse des variables physiologiques

Les données physiologiques ont également été étudiées afin d'évaluer leur contribution potentielle au modèle.

Les variables analysées comprennent :

- poids ;
- taille ;
- pression artérielle systolique ;

- pression artérielle diastolique ;
- fréquence cardiaque.

L'analyse montre que ces variables sont moins discriminantes que les scores cognitifs mais peuvent contribuer à améliorer les performances globales du modèle lorsqu'elles sont combinées à d'autres indicateurs.

Cette observation justifie leur conservation dans le jeu de données final.

3.6 Analyse des corrélations

3.6.1 Construction de la matrice de corrélation

Une matrice de corrélation a été calculée afin d'identifier les relations entre les différentes variables numériques.

Cette analyse permet de :

- détecter les variables redondantes ;
- identifier les variables fortement liées ;
- réduire la dimension du jeu de données.

Une heatmap a été générée afin de visualiser les coefficients de corrélation.

Cette représentation constitue l'un des principaux outils utilisés lors de la sélection des variables.

3.6.2 Principaux résultats

L'analyse a mis en évidence plusieurs groupes de variables fortement corrélées.

Les scores issus des tests cognitifs présentent notamment des relations significatives entre eux.

Par exemple :

- MMSE ;
- ADAS ;
- CDRSB ;
- CDGLOBAL ;
- CDMEMORY.

Ces résultats confirment que les différents tests mesurent des dimensions proches du fonctionnement cognitif.

À l'inverse, certaines variables physiologiques présentent des corrélations faibles avec le diagnostic final mais contribuent néanmoins à enrichir l'information disponible.

3.7 Sélection des variables

3.7.1 Difficulté rencontrée

La principale difficulté du projet réside dans le très grand nombre de variables disponibles après fusion des tables ADNI.

Le jeu de données initial contenait plusieurs centaines de variables.

L'utilisation directe de l'ensemble des variables aurait entraîné :

- un risque élevé de surapprentissage ;
- des temps d'entraînement importants ;
- une perte d'interprétabilité.

Une démarche de réduction progressive a donc été mise en œuvre.

3.7.2 Critères de sélection

Plusieurs critères ont été utilisés :

Pertinence médicale

Les variables reconnues comme significatives dans la littérature scientifique ont été privilégiées.

Corrélation avec la cible

Les variables présentant une relation forte avec le diagnostic ont été conservées.

Disponibilité des données

Les variables contenant trop de valeurs manquantes ont été écartées.

Performance des modèles

Les résultats obtenus lors des premiers entraînements ont servi à affiner progressivement la sélection.

3.8 Variables retenues pour la modélisation

À l'issue du processus de sélection, un ensemble restreint de variables a été conservé.

Parmi les principales variables retenues figurent :

Scores cognitifs

- CDGLOBAL
- CDMEMORY
- CDRSB
- CDJUDGE
- CDHOME
- CDCOMMUN
- MMSCORE
- TOTSCORE
- TOTAL13
- WORD2DL

Biomarqueurs

- ST101SV
- ST112SV
- ST120SV
- ST125SV

Variables physiologiques

- VSWEIGHT
- VSHEIGHT
- VSBPSYS
- VSBPDIA
- VSPULSE

Cet ensemble représente le compromis optimal entre performance et interprétabilité.

3.9 Visualisation et communication des résultats

L'analyse exploratoire a également donné lieu à la création de plusieurs visualisations destinées à faciliter la compréhension des résultats.

Les principaux graphiques réalisés sont :

- histogrammes ;
- boxplots ;
- heatmaps ;
- matrices de corrélation ;
- graphiques de répartition des classes ;
- tableaux de bord Power BI.

Ces représentations permettent de rendre les résultats accessibles à des utilisateurs non spécialistes de la Data Science.

3.10 Enseignements tirés de l'analyse exploratoire

L'analyse exploratoire a permis d'identifier plusieurs enseignements majeurs :

- les scores cognitifs constituent les variables les plus influentes ;
- certaines variables physiologiques apportent une information complémentaire ;
- les biomarqueurs renforcent les capacités prédictives du modèle ;
- plusieurs variables initiales étaient redondantes ou peu informatives ;
- la réduction de dimension améliore la robustesse des modèles.

Ces observations ont guidé l'ensemble des choix réalisés lors des phases de modélisation.

3.11 Bilan du Bloc 2

Cette phase d'analyse exploratoire a permis de transformer un ensemble complexe de données médicales en connaissances exploitables pour la modélisation.

Les travaux réalisés ont permis :

- d'évaluer la qualité des données ;
- d'identifier les variables les plus pertinentes ;
- de comprendre les relations entre les différents indicateurs ;
- de préparer la sélection des variables ;

- de produire des visualisations compréhensibles.

L'EDA a joué un rôle déterminant dans la réussite du projet en fournissant les éléments nécessaires à la construction des modèles de Machine Learning.

Le chapitre suivant présentera la conception, l'entraînement et l'évaluation des différents modèles prédictifs développés dans le cadre du projet.

CHAPITRE 4 – MODÉLISATION MACHINE LEARNING (BLOC 3)

Annexes complémentaires

- ANNEXE E – COMPARAISON DES MODÈLES
- ANNEXE F – MATRICES DE CONFUSION
- ANNEXE G – IMPORTANCE DES VARIABLES

4.1 Introduction et objectifs

Après la phase de collecte, de préparation et d'analyse exploratoire des données, l'étape suivante consiste à développer des modèles capables d'estimer automatiquement le risque de maladie d'Alzheimer à partir des informations médicales disponibles.

Cette phase constitue le cœur du projet Data Science puisqu'elle vise à transformer les connaissances extraites des données en un outil prédictif capable d'assister les professionnels de santé dans l'identification précoce des patients à risque.

L'objectif principal est de construire un modèle capable de distinguer les différents états cognitifs observés dans la base ADNI à partir d'un ensemble restreint de variables cliniques, cognitives et biologiques.

Pour atteindre cet objectif, plusieurs algorithmes de Machine Learning ont été étudiés et comparés.

La démarche retenue repose sur :

- la préparation des données ;
- la sélection des variables ;
- la séparation des jeux d'entraînement et de test ;
- l'entraînement de plusieurs modèles ;
- l'évaluation des performances ;
- la sélection automatique du meilleur modèle ;
- la sauvegarde des artefacts pour l'industrialisation.

Cette méthodologie permet de garantir la reproductibilité des résultats tout en facilitant l'intégration future du modèle dans l'application finale.

4.2 Préparation des données pour le Machine Learning

4.2.1 Constitution du jeu d'apprentissage

Une fois les données consolidées et nettoyées, il a été nécessaire de constituer un jeu de données adapté aux algorithmes de Machine Learning.

Le jeu final est composé :

- des variables explicatives sélectionnées ;
- de la variable cible correspondant au diagnostic médical.

Les variables explicatives regroupent principalement :

Variables cognitives

- MMSCORE
- TOTAL13
- TOTSCORE
- CDRSB
- CDGLOBAL
- CDMEMORY
- CDHOME
- CDJUDGE
- CDCOMMUN
- WORD2DL

Biomarqueurs

- ST101SV
- ST112SV
- ST120SV
- ST125SV

Variables physiologiques

- VSWEIGHT
- VSHEIGHT
- VSBPSYS

- VSBPDIA
- VSPULSE

Cette sélection résulte du travail réalisé lors de l'analyse exploratoire et vise à conserver uniquement les variables les plus pertinentes.

4.2.2 Réduction de la dimension

L'une des principales difficultés rencontrées durant le projet concerne le nombre important de variables disponibles.

Après fusion des différentes tables ADNI, plusieurs centaines de variables étaient présentes.

L'utilisation directe de l'ensemble des données aurait entraîné :

- une augmentation du risque de surapprentissage ;
- une complexification du modèle ;
- des temps d'entraînement plus importants ;
- une perte d'interprétabilité.

Une démarche progressive de réduction a donc été mise en œuvre.

Cette étape représente l'un des principaux défis du projet.

Le processus de sélection a permis de réduire significativement le nombre de variables tout en conservant les informations médicales les plus pertinentes pour la prédiction.

4.2.3 Séparation des données

Afin d'évaluer correctement les performances des modèles, les données ont été séparées en deux ensembles :

Jeu d'entraînement

Utilisé pour apprendre les relations entre les variables et le diagnostic.

Jeu de test

Utilisé exclusivement pour mesurer les performances sur des données jamais vues par le modèle.

Cette séparation permet d'obtenir une estimation réaliste des performances futures du système.

4.3 Choix des modèles étudiés

Plusieurs algorithmes ont été sélectionnés afin de comparer différentes approches de classification.

Le choix des modèles repose sur leur popularité dans les projets de Machine Learning appliqués aux données tabulaires ainsi que sur leur capacité à gérer des données médicales complexes.

4.3.1 Régression Logistique

La régression logistique constitue souvent le modèle de référence dans les projets de classification.

Elle présente plusieurs avantages :

- simplicité ;
- rapidité ;
- interprétabilité.

Elle permet d'obtenir un premier niveau de comparaison pour évaluer l'apport des modèles plus avancés.

4.3.2 Random Forest

Le Random Forest repose sur un ensemble d'arbres de décision construits aléatoirement.

Cette approche présente plusieurs avantages :

- robustesse ;
- résistance au surapprentissage ;
- gestion efficace des variables non linéaires ;
- interprétabilité via l'importance des variables.

Ces caractéristiques en font un candidat particulièrement adapté aux données médicales.

4.3.3 Gradient Boosting

Le Gradient Boosting repose sur une logique d'amélioration progressive des erreurs commises par les modèles précédents.

Cette méthode permet généralement d'obtenir :

- une excellente précision ;
- une bonne capacité de généralisation ;

- une forte robustesse.

Son efficacité est reconnue dans de nombreux problèmes de classification médicale.

4.3.4 Réseau de neurones Keras

Un modèle de Deep Learning léger a également été testé à partir de données tabulaires.

L'objectif est d'évaluer l'apport potentiel des réseaux de neurones sur les données cliniques utilisées.

Cette approche constitue un intermédiaire entre les algorithmes traditionnels et l'expérimentation CNN présentée dans le chapitre suivant.

4.4 Processus d'entraînement

4.4.1 Pipeline automatisé

Afin de garantir la reproductibilité des résultats, un pipeline d'entraînement automatisé a été développé.

Ce pipeline réalise automatiquement :

- le chargement des données ;
- la préparation des variables ;
- l'entraînement des modèles ;
- le calcul des métriques ;
- la comparaison des performances ;
- la sauvegarde du meilleur modèle.

Cette automatisation permet de reproduire facilement les expérimentations et facilite les évolutions futures du projet.

4.4.2 Gestion des artefacts

Chaque modèle entraîné est sauvegardé sous forme d'artefact.

Les artefacts comprennent notamment :

- le modèle entraîné ;
- les métriques associées ;
- les paramètres utilisés.

Le meilleur modèle est automatiquement identifié puis stocké pour être utilisé par l'API de prédiction.

Cette approche simplifie considérablement l'industrialisation.

4.5 Évaluation des performances

4.5.1 Métriques utilisées

Dans un contexte médical, l'évaluation d'un modèle ne peut pas se limiter à l'accuracy.

Plusieurs indicateurs ont été retenus :

Accuracy

Mesure la proportion de prédictions correctes.

Precision

Mesure la fiabilité des prédictions positives.

Recall

Mesure la capacité du modèle à détecter les cas réellement positifs.

F1-Score

Moyenne harmonique entre la précision et le rappel.

Cette métrique a été privilégiée comme critère principal de sélection.

4.5.2 Importance du Recall

Dans le domaine médical, le rappel (Recall) est particulièrement important.

Un faux négatif correspond à un patient malade identifié à tort comme sain.

Les conséquences potentielles peuvent être importantes :

- retard de prise en charge ;
- absence de suivi médical adapté ;
- aggravation de la pathologie.

Pour cette raison, une attention particulière a été portée à cette métrique lors de l'évaluation des modèles.

4.6 Résultats obtenus

Les résultats obtenus montrent des performances élevées pour l'ensemble des modèles étudiés.

Modèle	Accuracy	Precision	Recall	F1-Score
Random Forest	90,41 %	92,45 %	91,47 %	91,96 %
Gradient Boosting	90,28 %	92,03 %	91,74 %	91,88 %
Keras Classifier	90,00 %	92,67 %	90,47 %	91,56 %

Les écarts observés entre les modèles sont relativement faibles.

Cela traduit la qualité du travail de préparation des données réalisé en amont.

4.7 Sélection du modèle final

Le modèle retenu est le Random Forest.

Ce choix ne repose pas uniquement sur les performances brutes mais également sur plusieurs critères complémentaires.

Performance

Le Random Forest obtient le meilleur F1-score global.

Robustesse

Le modèle présente une excellente stabilité face aux variations des données.

Interprétabilité

L'analyse de l'importance des variables permet de comprendre les mécanismes de décision du modèle.

Industrialisation

Le modèle est facilement sérialisable et déployable dans une architecture API.

Ces caractéristiques en font le meilleur compromis pour une utilisation opérationnelle.

4.8 Importance des variables

L'un des avantages du Random Forest réside dans sa capacité à mesurer l'importance relative des variables.

L'analyse réalisée montre que les variables les plus influentes sont principalement issues :

- des tests cognitifs ;

- des évaluations cliniques ;
- des biomarqueurs.

Les variables les plus importantes comprennent notamment :

- MMSCORE ;
- TOTAL13 ;
- CDRSB ;
- CDGLOBAL ;
- CDMEMORY.

Ces résultats sont cohérents avec les connaissances médicales actuelles concernant la maladie d'Alzheimer.

Cette cohérence constitue un élément important pour renforcer la confiance dans le modèle développé.

4.9 Limites de l'approche

Malgré les performances obtenues, plusieurs limites doivent être soulignées.

Données longitudinales

Certaines informations temporelles n'ont pas été pleinement exploitées.

Taille de l'échantillon

Bien que la base ADNI soit riche, elle demeure limitée par rapport aux données hospitalières à grande échelle.

Généralisation

Les performances observées concernent principalement la population représentée dans ADNI.

Une validation externe serait nécessaire avant toute utilisation clinique.

Interprétation médicale

Le modèle constitue un outil d'aide à la décision et ne peut se substituer à un diagnostic médical.

4.10 Contribution au projet

Cette phase de Machine Learning représente le cœur fonctionnel de la solution développée.

Elle permet :

- d'automatiser l'analyse des données patients ;
- d'estimer le risque de maladie ;
- de fournir un score prédictif exploitable ;
- d'alimenter l'API de prédiction utilisée par l'application.

Les résultats obtenus démontrent la pertinence de l'approche retenue et valident la faisabilité d'une détection précoce basée sur les données ADNI.

4.11 Bilan du Bloc 3

Le travail réalisé dans le cadre de ce bloc a permis de développer et d'évaluer plusieurs modèles prédictifs appliqués à la détection précoce de la maladie d'Alzheimer.

Les principales réalisations sont :

- préparation du jeu d'apprentissage ;
- réduction de la dimension ;
- comparaison de plusieurs algorithmes ;
- automatisation des entraînements ;
- sélection du meilleur modèle ;
- génération des artefacts nécessaires à l'industrialisation.

Les résultats obtenus démontrent qu'il est possible d'atteindre des performances élevées à partir d'un ensemble limité de variables cliniques et cognitives.

Le modèle Random Forest constitue désormais le moteur prédictif principal de l'application développée.

Le chapitre suivant présentera une expérimentation complémentaire basée sur l'analyse d'images IRM cérébrales à l'aide de techniques de Deep Learning.

CHAPITRE 5 – EXPÉRIMENTATION DEEP LEARNING SUR IMAGES IRM (BLOC 4)

Annexes complémentaires

- ANNEXE H – ARCHITECTURE CNN

5.1 Introduction

En complément de l'approche Machine Learning basée sur les données cliniques et cognitives, une expérimentation de Deep Learning a été menée dans le cadre du projet.

L'objectif de cette expérimentation est d'évaluer la capacité des réseaux de neurones convolutifs (Convolutional Neural Networks – CNN) à détecter automatiquement des caractéristiques visuelles associées à la maladie d'Alzheimer à partir d'images d'IRM cérébrales.

Cette approche s'inscrit dans une logique de recherche complémentaire. Contrairement au modèle principal présenté dans le chapitre précédent, elle n'est pas intégrée à la solution finale déployée mais permet d'explorer le potentiel des techniques de Deep Learning appliquées à l'imagerie médicale.

L'expérimentation vise notamment à répondre aux questions suivantes :

- Les images IRM contiennent-elles suffisamment d'informations pour permettre une classification automatique ?
- Les performances obtenues sont-elles comparables à celles des modèles tabulaires ?
- Cette approche pourrait-elle être intégrée à une future version de la solution ?

Les résultats obtenus démontrent l'intérêt du Deep Learning dans le domaine médical tout en mettant en évidence certaines limites liées à la disponibilité et à la qualité des données d'imagerie.

5.2 Contexte scientifique

5.2.1 L'apport de l'imagerie cérébrale

L'imagerie par Résonance Magnétique (IRM) constitue aujourd'hui l'un des outils les plus utilisés dans le diagnostic et le suivi des maladies neurodégénératives.

Elle permet d'observer directement certaines modifications anatomiques du cerveau pouvant être associées à la progression de la maladie d'Alzheimer.

Parmi les principaux marqueurs observables figurent :

- l'atrophie cérébrale ;
- la réduction du volume de l'hippocampe ;

- l'élargissement des ventricules ;
- les modifications de certaines structures corticales.

Ces altérations apparaissent progressivement au cours de l'évolution de la maladie.

L'analyse automatisée des images IRM représente donc un domaine particulièrement prometteur pour la détection précoce des troubles cognitifs.

5.2.2 Pourquoi utiliser le Deep Learning ?

Les méthodes classiques d'analyse d'image nécessitent généralement la définition manuelle de caractéristiques visuelles.

À l'inverse, les réseaux de neurones convolutifs sont capables d'apprendre automatiquement les motifs visuels pertinents directement à partir des données.

Cette capacité présente plusieurs avantages :

- automatisation de l'extraction des caractéristiques ;
- adaptation aux données complexes ;
- performances élevées sur les tâches de classification ;
- réduction de l'intervention humaine.

Ces propriétés expliquent l'utilisation croissante du Deep Learning dans les applications médicales modernes.

5.3 Présentation du Deep Learning

5.3.1 Définition

Le Deep Learning est une branche de l'intelligence artificielle reposant sur l'utilisation de réseaux de neurones artificiels composés de plusieurs couches successives.

Ces couches permettent d'apprendre progressivement des représentations de plus en plus complexes des données.

Dans le cas de l'analyse d'images, les couches convolutives permettent notamment de détecter :

- des contours ;
- des textures ;
- des formes ;
- des structures anatomiques.

L'ensemble de ces informations est ensuite utilisé pour réaliser une classification.

5.3.2 Réseaux de neurones convolutifs (CNN)

Les CNN sont particulièrement adaptés aux données visuelles.

Leur architecture repose généralement sur plusieurs composants :

Couches convolutives

Elles extraient automatiquement les caractéristiques importantes des images.

Couches de pooling

Elles réduisent la dimension des données tout en conservant l'information utile.

Couches entièrement connectées

Elles réalisent la classification finale.

Cette architecture permet de construire des modèles particulièrement performants pour la reconnaissance d'images.

5.4 Préparation des données IRM

5.4.1 Collecte des images

Les images utilisées proviennent de la base ADNI.

Ces examens ont été réalisés dans le cadre du suivi médical des patients inclus dans le programme de recherche.

Chaque image est associée à un diagnostic permettant de constituer les classes utilisées lors de l'apprentissage.

5.4.2 Prétraitement des images

Avant l'entraînement du modèle, plusieurs opérations de préparation ont été nécessaires.

Les principales étapes comprennent :

- chargement des images ;
- homogénéisation du format ;
- redimensionnement ;
- normalisation des pixels ;
- création des jeux d'entraînement et de validation.

Ces transformations permettent de rendre les images compatibles avec les exigences du réseau de neurones.

5.4.3 Constitution des jeux de données

Comme pour les modèles tabulaires, les données ont été séparées en plusieurs ensembles :

Jeu d'entraînement

Utilisé pour apprendre les caractéristiques visuelles.

Jeu de validation

Utilisé pour mesurer les performances durant l'apprentissage.

Cette séparation permet de surveiller le comportement du modèle et de détecter d'éventuels phénomènes de surapprentissage.

5.5 Architecture du modèle CNN

L'architecture développée repose sur un réseau de neurones convolutifs classique adapté aux contraintes du projet.

Le modèle est composé de plusieurs blocs successifs :

- couches convolutives ;
- couches de pooling ;
- couches de régularisation ;
- couches denses de classification.

Chaque couche permet d'extraire progressivement des informations de plus haut niveau à partir des images cérébrales.

Le processus d'apprentissage ajuste automatiquement plusieurs milliers de paramètres afin d'optimiser la capacité de classification du modèle.

5.6 Entraînement du modèle

5.6.1 Fonction de perte

L'apprentissage du réseau repose sur une fonction de perte mesurant l'écart entre les prédictions du modèle et les diagnostics réels.

L'objectif est de minimiser progressivement cette erreur au cours des itérations.

5.6.2 Optimisation

L'algorithme d'optimisation ajuste les poids du réseau afin d'améliorer progressivement les performances.

Au fil des époques d'entraînement, le modèle apprend à reconnaître les motifs caractéristiques associés aux différentes catégories de patients.

5.6.3 Suivi de l'apprentissage

Plusieurs indicateurs ont été suivis :

- accuracy ;
- loss ;
- validation accuracy ;
- validation loss.

Ces courbes permettent de vérifier que le modèle apprend correctement sans mémoriser excessivement les données.

5.7 Résultats obtenus

Les résultats observés montrent des performances très élevées.

Les métriques enregistrées indiquent une précision proche de 99 % sur les données utilisées lors de l'expérimentation.

Ces résultats démontrent la capacité du réseau à identifier des différences visuelles significatives entre les catégories étudiées.

Cependant, ces performances doivent être interprétées avec prudence.

Dans le domaine médical, des scores très élevés peuvent parfois révéler :

- un surapprentissage ;
- un volume de données limité ;
- une forte homogénéité du jeu d'entraînement.

Une analyse approfondie est donc nécessaire avant toute utilisation clinique.

5.8 Analyse critique des résultats

5.8.1 Forces de l'approche

L'expérimentation met en évidence plusieurs points positifs.

Détection automatique

Le modèle apprend directement à partir des images sans intervention humaine dans l'extraction des caractéristiques.

Excellentes performances

Les résultats obtenus démontrent le potentiel des CNN pour l'analyse de données médicales complexes.

Potentiel clinique

L'imagerie constitue une source d'information particulièrement riche dans le contexte de la maladie d'Alzheimer.

5.8.2 Limites observées

Malgré les résultats obtenus, plusieurs limites doivent être soulignées.

Taille du jeu d'images

Le volume disponible demeure inférieur à celui généralement utilisé dans les grands projets de Deep Learning.

Coût de calcul

L'entraînement des CNN nécessite davantage de ressources matérielles que les modèles tabulaires.

Interprétabilité

Les mécanismes de décision d'un réseau de neurones restent plus difficiles à expliquer que ceux d'un Random Forest.

Validation clinique

Des études complémentaires seraient nécessaires avant toute utilisation en contexte médical réel.

5.9 Comparaison avec le Machine Learning tabulaire

L'expérimentation permet de comparer deux approches complémentaires :

Critère	Machine Learning Deep Learning	
Type de données	Variables cliniques	Images IRM
Interprétabilité	Élevée	Faible

Critère Machine Learning Deep Learning

Temps d'entraînement	Faible	Important
Industrialisation	Simple	Plus complexe
Performance	Très élevée	Très élevée

Cette comparaison montre que les deux approches répondent à des problématiques différentes.

Le modèle tabulaire demeure le choix principal pour la solution déployée tandis que le CNN représente une piste d'amélioration future.

5.10 Perspectives d'évolution

L'expérimentation ouvre plusieurs perspectives intéressantes.

Fusion multimodale

Combiner :

- données cliniques ;
- biomarqueurs ;
- données IRM.

Cette approche pourrait permettre d'améliorer encore les performances prédictives.

Transfer Learning

L'utilisation de modèles pré-entraînés pourrait réduire les besoins en données.

Explicabilité

L'ajout de techniques d'interprétation permettrait de mieux comprendre les décisions du réseau.

Déploiement intégré

Une future version du projet pourrait intégrer le CNN directement dans l'architecture FastAPI.

5.11 Contribution au projet

Même si le CNN n'est pas utilisé dans la version finale déployée, cette expérimentation apporte une forte valeur ajoutée au projet.

Elle démontre :

- la maîtrise des techniques de Deep Learning ;
- la capacité à traiter des données d'imagerie médicale ;
- la compréhension des problématiques liées aux CNN ;
- l'ouverture vers des architectures multimodales plus avancées.

Cette expérimentation complète efficacement l'approche Machine Learning présentée dans le chapitre précédent.

5.12 Bilan du Bloc 4

L'expérimentation Deep Learning menée sur les images IRM cérébrales a permis d'évaluer le potentiel des réseaux de neurones convolutifs dans le contexte de la détection précoce de la maladie d'Alzheimer.

Les résultats obtenus démontrent que les images médicales constituent une source d'information particulièrement riche et ouvrent des perspectives intéressantes pour les futures évolutions du projet.

Toutefois, les contraintes de calcul, les besoins en données et les enjeux d'interprétabilité conduisent à privilégier, dans la version actuelle de la solution, le modèle Random Forest basé sur les données cliniques et cognitives.

Le chapitre suivant présentera l'industrialisation complète de la solution ainsi que les choix techniques ayant permis son déploiement sous forme d'application accessible aux utilisateurs finaux.

CHAPITRE 6 – INDUSTRIALISATION ET DÉPLOIEMENT DE LA SOLUTION (BLOC 5)

Annexes complémentaires

- ANNEXE J – DOCUMENTATION API FASTAPIAnnexe T – Diagramme d'industrialisation
- ANNEXE L – TABLEAUX DE BORD POWER BI
- ANNEXE M – DÉPLOIEMENT DOCKER ET RENDER

6.1 Introduction

La réalisation d'un modèle performant constitue une étape importante d'un projet Data Science, mais elle ne représente qu'une partie de la valeur créée.

Pour qu'un modèle puisse être utilisé dans un contexte réel, il doit être intégré dans une architecture logicielle permettant :

- l'accès aux données ;
- l'exécution des prédictions ;
- la restitution des résultats ;
- la maintenance du système ;
- le déploiement en production.

Cette phase est généralement désignée sous le terme d'industrialisation.

Dans le cadre du projet Alzheimer, une architecture complète a été développée afin de transformer le modèle Machine Learning en une application exploitable par les utilisateurs.

L'objectif poursuivi est de démontrer la capacité à concevoir une chaîne complète allant de la donnée brute jusqu'à la restitution des résultats via une interface accessible.

Cette démarche répond directement aux compétences attendues d'un Concepteur Développeur en Science des Données.

6.2 Objectifs de l'industrialisation

L'industrialisation du projet poursuit plusieurs objectifs :

Automatisation

Permettre l'exécution automatique des traitements sans intervention manuelle.

Reproductibilité

Garantir la possibilité de reproduire les résultats à partir des mêmes données.

Accessibilité

Rendre les prédictions accessibles à des utilisateurs non techniques.

Maintenabilité

Faciliter les évolutions futures du système.

Déploiement

Permettre l'utilisation de l'application dans un environnement cloud.

Pour répondre à ces objectifs, plusieurs technologies complémentaires ont été mises en œuvre.

6.3 Architecture globale de la solution

L'architecture développée repose sur une séparation claire des responsabilités entre les différents composants.

Le flux général est le suivant :

ADNI

↓

Python / KNIME

↓

Supabase

↓

Préprocessing

↓

Machine Learning

↓

FastAPI

↓

Streamlit

↓

Power BI



Render

Cette organisation permet d'isoler chaque couche fonctionnelle tout en assurant leur interconnexion.

L'architecture retenue favorise :

- la modularité ;
- la maintenance ;
- la réutilisation ;
- l'évolutivité.

6.4 Gestion des données

6.4.1 Centralisation des données

Les données préparées sont stockées dans Supabase.

Cette plateforme joue le rôle de Data Lake du projet.

Les jeux de données y sont conservés sous forme de tables structurées permettant :

- la traçabilité ;
- la réutilisation ;
- l'alimentation des modèles.

Cette approche évite de répéter les traitements de préparation à chaque exécution.

6.4.2 Organisation des jeux de données

Plusieurs tables spécifiques ont été utilisées :

X_train

Variables d'entraînement.

X_test

Variables de test.

y_train

Variable cible d'entraînement.

y_test

Variable cible de validation.

ALZ_SILVER

Jeu de données consolidé préparé pour les analyses.

Cette organisation facilite la séparation des responsabilités et améliore la lisibilité du pipeline.

6.5 Gestion des modèles

6.5.1 Sauvegarde des modèles

Les modèles entraînés sont automatiquement sauvegardés sous forme d'artefacts.

Cette sauvegarde permet :

- de conserver les résultats ;
- de réutiliser les modèles ;
- d'éviter les réentraînements inutiles.

Les artefacts sont enregistrés à l'aide de Joblib.

6.5.2 Versionnement

Chaque modèle est enregistré avec un numéro de version.

Cette stratégie permet :

- d'identifier les évolutions ;
- de comparer les performances ;
- de revenir à une version précédente si nécessaire.

Le dépôt GitHub assure également le suivi des évolutions du code source.

6.5.3 Sélection automatique du meilleur modèle

Un mécanisme automatique compare les performances obtenues par les différents algorithmes.

Le modèle présentant le meilleur F1-Score est automatiquement sélectionné.

Dans le cadre du projet, cette procédure a permis d'identifier le Random Forest comme modèle de référence.

Cette automatisation facilite considérablement la maintenance future du système.

6.6 Développement de l'API FastAPI

6.6.1 Rôle de l'API

Une API REST a été développée afin d'exposer les fonctionnalités du modèle de prédiction.

L'API constitue l'interface entre :

- le modèle Machine Learning ;
- l'interface utilisateur ;
- les applications externes.

Elle permet de transformer un modèle Data Science en un service utilisable par différents systèmes.

6.6.2 Choix de FastAPI

FastAPI a été retenu pour plusieurs raisons :

- performance élevée ;
- simplicité de développement ;
- documentation automatique ;
- compatibilité avec Python.

Cette technologie est particulièrement adaptée aux projets de Machine Learning.

6.6.3 Fonctionnement

L'utilisateur transmet les caractéristiques d'un patient via une requête.

L'API réalise alors :

1. la validation des données ;
2. le chargement du modèle ;
3. la prédiction ;
4. le renvoi du résultat.

Cette architecture garantit une séparation claire entre la logique métier et l'interface utilisateur.

6.6.4 Documentation Swagger

FastAPI génère automatiquement une documentation interactive.

Cette documentation permet :

- de tester les endpoints ;
- de vérifier les paramètres ;
- de faciliter les développements futurs.

La présence d'une documentation API constitue un élément important pour la maintenabilité du projet.

6.7 Développement de l'interface utilisateur

6.7.1 Objectifs

Le modèle développé doit être utilisable par des personnes ne possédant pas nécessairement de compétences techniques.

Une interface utilisateur a donc été développée afin de simplifier l'utilisation du système.

6.7.2 Choix de Streamlit

Streamlit a été retenu pour plusieurs raisons :

- rapidité de développement ;
- simplicité d'utilisation ;
- intégration native avec Python ;
- compatibilité avec les applications Data Science.

Cette technologie permet de transformer rapidement un modèle en application web.

6.7.3 Fonctionnement

L'utilisateur saisit les caractéristiques du patient à travers un formulaire.

Les informations sont ensuite transmises à l'API FastAPI.

La réponse retournée par l'API est immédiatement affichée à l'écran sous forme de résultat interprétable.

Cette approche rend le modèle accessible à des utilisateurs non spécialisés.

6.8 Conteneurisation avec Docker

6.8.1 Pourquoi Docker ?

Docker permet d'encapsuler l'ensemble de l'application dans un environnement isolé.

Cette approche présente plusieurs avantages :

- reproductibilité ;
- portabilité ;
- simplification du déploiement ;
- réduction des conflits de dépendances.

6.8.2 Architecture des conteneurs

Le projet repose sur plusieurs composants :

Backend

FastAPI

Frontend

Streamlit

Chaque composant dispose de son propre environnement d'exécution.

Cette séparation facilite les mises à jour et améliore la maintenabilité.

6.8.3 Docker Compose

Docker Compose permet de lancer simultanément les différents services.

Cette solution simplifie :

- les tests locaux ;
- les déploiements ;
- la gestion des dépendances.

L'ensemble du système peut ainsi être reproduit rapidement sur une nouvelle machine.

6.9 Déploiement Cloud avec Render

6.9.1 Choix de Render

Le projet a été déployé sur la plateforme Render.

Cette solution a été retenue pour :

- sa simplicité ;
- son intégration avec GitHub ;
- son coût réduit ;
- sa compatibilité avec Docker.

6.9.2 Déploiement du backend

L'API FastAPI est hébergée sur Render et expose les services de prédiction.

Le modèle Machine Learning est chargé automatiquement au démarrage de l'application.

Les utilisateurs peuvent ainsi accéder aux prédictions à distance.

6.9.3 Déploiement du frontend

L'interface Streamlit est également déployée sur Render.

Cette application communique directement avec l'API afin d'obtenir les résultats des prédictions.

L'ensemble constitue une solution accessible via un simple navigateur web.

6.9.4 Limites de la version gratuite

Le projet utilise l'offre gratuite de Render.

Cette solution est adaptée à un contexte pédagogique mais présente certaines limitations :

- temps de démarrage ;
- ressources limitées ;
- disponibilité réduite.

Pour une utilisation professionnelle, une offre payante serait recommandée.

6.10 Restitution et visualisation avec Power BI

6.10.1 Objectifs

La restitution des résultats constitue une étape essentielle pour permettre l'exploitation des analyses.

Power BI a été utilisé afin de :

- visualiser les données ;

- explorer les indicateurs ;
- communiquer les résultats.

6.10.2 Modélisation des données

Les transformations et le modèle en étoile ont été réalisés directement dans Power BI.

Cette approche permet :

- de simplifier les analyses ;
- d'améliorer les performances ;
- de faciliter la création des rapports.

Il convient de préciser qu'aucun Data Warehouse dédié n'a été mis en place. La structuration analytique est réalisée directement dans Power BI.

6.10.3 Tableaux de bord

Plusieurs tableaux de bord ont été développés :

- suivi des diagnostics ;
- répartition des patients ;
- analyse des scores cognitifs ;
- facteurs de risque.

Ces visualisations permettent aux utilisateurs d'explorer les données sans connaissance technique particulière.

6.11 Limites techniques et perspectives d'évolution

Le projet a été réalisé dans le cadre d'une preuve de concept (Proof of Concept – POC) visant à démontrer la faisabilité d'une solution de détection précoce de la maladie d'Alzheimer basée sur les données ADNI.

L'objectif principal était de valider l'ensemble de la chaîne de traitement, depuis l'intégration des données jusqu'au déploiement d'un service de prédiction accessible via une interface web.

Dans ce contexte, certaines fonctionnalités habituellement présentes dans un environnement de production n'ont pas été mises en œuvre.

Par exemple :

- séparation des environnements de développement, de recette et de production ;

- gestion avancée des droits d'accès ;
- authentification des utilisateurs ;
- supervision applicative ;
- journalisation centralisée ;
- gestion des secrets à l'échelle d'une organisation.

Ces éléments ne constituaient pas un prérequis du projet mais représentent des axes d'amélioration naturels dans une perspective d'industrialisation à grande échelle.

Dans un contexte professionnel, ces responsabilités relèvent généralement d'une collaboration entre plusieurs acteurs :

- Data Engineer ;
- Data Scientist ;
- Développeur Backend ;
- Architecte Cloud ;
- Équipes DevOps ;
- Responsables Sécurité.

L'architecture développée a néanmoins été conçue de manière suffisamment modulaire pour permettre l'intégration future de ces mécanismes sans remise en cause des composants existants.

6.12 Contribution aux compétences RNCP

Cette phase d'industrialisation permet de démontrer plusieurs compétences clés du référentiel :

Développement de solutions Data

Conception d'une architecture complète.

Déploiement

Mise en production d'un service de prédiction.

Intégration

Connexion des différentes briques technologiques.

Vulgarisation

Mise à disposition d'interfaces accessibles aux utilisateurs métiers.

L'industrialisation constitue ainsi une étape essentielle permettant de transformer un modèle théorique en solution opérationnelle.

6.13 Bilan du Bloc 5

Le travail réalisé dans le cadre de ce bloc a permis de concevoir une architecture complète allant de la préparation des données jusqu'à la restitution des résultats.

Les principales réalisations sont :

- gestion centralisée des données ;
- versionnement des modèles ;
- développement d'une API FastAPI ;
- création d'une interface Streamlit ;
- conteneurisation Docker ;
- déploiement Render ;
- visualisation Power BI.

Cette architecture garantit la reproductibilité, la maintenabilité et l'accessibilité de la solution développée.

Le chapitre suivant présentera le pilotage du projet, les méthodes de gestion mises en œuvre ainsi que les actions de communication et de vulgarisation réalisées auprès des parties prenantes.

CHAPITRE 7 – PILOTAGE, COMMUNICATION ET GOUVERNANCE DU PROJET (BLOC 6)

Annexes complémentaires

- ANNEXE I – GESTION DE PROJET JIRA
- ANNEXE K – RAPPORT PIA
- ANNEXE K Bis – RAPPORT COMPLET ANALYSE IMPACT RGPD PIA

7.1 Introduction

La réussite d'un projet Data Science ne repose pas uniquement sur la qualité des algorithmes développés. Elle dépend également de la capacité à organiser les travaux, coordonner les intervenants, assurer la traçabilité des décisions et communiquer efficacement avec les différentes parties prenantes.

Dans le cadre du projet de détection précoce de la maladie d'Alzheimer, une démarche structurée de gestion de projet a été mise en œuvre afin de garantir le bon déroulement des travaux, le respect des objectifs pédagogiques et la qualité des livrables produits.

Cette phase répond directement aux compétences du référentiel RNCP relatives à :

- la gestion de projet ;
- la coordination des activités ;
- la communication auprès des parties prenantes ;
- la transmission des résultats ;
- la gouvernance des données.

Le projet a été mené selon une approche Agile permettant d'adapter les développements aux contraintes rencontrées tout au long du cycle de vie de la solution.

7.2 Organisation de l'équipe projet

Le projet a été réalisé dans le cadre de la formation Concepteur Développeur en Science des Données.

L'équipe projet était composée de :

- Magalie CESARINI
- Bruce VIGNOLLES
- Assmaa ABDELMOUMNI

Répartition des responsabilités

Afin de favoriser l'implication de l'ensemble des membres de l'équipe et de développer une vision globale du projet, les rôles clés de la méthodologie Scrum ont été répartis de manière tournante tout au long des différents sprints.

Les rôles de **Scrum Master**, chargé de la coordination opérationnelle, du suivi des tâches dans Jira et de l'animation des points d'avancement, ainsi que de **Product Owner**, responsable de la validation fonctionnelle des livrables et de la vérification de la conformité des pipelines développés, ont alterné à chaque sprint.

Cette organisation a permis à chaque membre de l'équipe d'acquérir une compréhension complète des enjeux techniques, fonctionnels et organisationnels du projet. Elle a également renforcé la polyvalence, l'autonomie et la capacité de coordination de chacun, tout en favorisant le partage des connaissances et la prise de décision collective.

Cette approche s'est révélée particulièrement adaptée dans le cadre d'un projet pédagogique de Data Science, où l'objectif ne consiste pas uniquement à produire une solution technique, mais également à développer les compétences de gestion de projet, de communication et de collaboration attendues dans un contexte professionnel.

La répartition des activités a permis de couvrir l'ensemble des dimensions du projet :

- collecte et préparation des données ;
- analyse exploratoire ;
- développement des modèles ;
- expérimentation Deep Learning ;
- industrialisation ;
- documentation ;
- préparation de la soutenance.

7.3 Méthodologie de gestion de projet

7.3.1 Choix d'une approche Agile

Le projet a été conduit selon les principes de la méthode Agile Scrum.

Cette méthodologie repose sur un découpage du projet en cycles courts appelés sprints.

L'objectif est de produire régulièrement des livrables fonctionnels tout en conservant une forte capacité d'adaptation face aux difficultés rencontrées.

L'approche Agile présente plusieurs avantages :

- meilleure visibilité sur l'avancement ;
- priorisation des tâches ;
- amélioration continue ;
- adaptation aux changements.

Ces caractéristiques sont particulièrement adaptées aux projets Data Science où les résultats expérimentaux peuvent conduire à réorienter certaines décisions techniques.

7.3.2 Découpage du projet

Le projet a été structuré autour de plusieurs grandes phases :

Phase 1 – Collecte des données

- découverte d'ADNI ;
- sélection des tables ;
- compréhension des données.

Phase 2 – Préparation des données

- nettoyage ;
- fusion ;
- sélection des variables.

Phase 3 – Analyse exploratoire

- statistiques descriptives ;
- visualisations ;
- corrélations.

Phase 4 – Modélisation

- entraînement ;
- comparaison ;
- sélection du meilleur modèle.

Phase 5 – Industrialisation

- API ;
- interface utilisateur ;
- déploiement.

Phase 6 – Documentation et soutenance

- rédaction du rapport ;
- création des supports de présentation ;
- préparation de la démonstration.

Cette organisation a permis de conserver une progression cohérente tout au long du projet.

7.4 Utilisation de Jira

7.4.1 Gestion du backlog

L'ensemble des travaux a été suivi à l'aide de Jira.

Cet outil a permis de centraliser :

- les besoins ;
- les tâches ;
- les priorités ;
- l'avancement du projet.

Chaque fonctionnalité a été décrite sous forme de User Story afin de faciliter le suivi des développements.

7.4.2 Suivi des indicateurs

Les principaux indicateurs observés sont :

Indicateur	Valeur
Nombre de sprints	9
Nombre d'épics	8
Nombre de User Stories	37

Indicateur	Valeur
------------	--------

Nombre de Story Points	88
------------------------	----

Ces éléments permettent d'évaluer la charge de travail réalisée durant le projet.

Ils témoignent également de la structuration des activités menées par l'équipe.

7.4.3 Organisation des épics

Les principaux épics identifiés concernent :

- Collecte des données ;
- Préparation des données ;
- Analyse exploratoire ;
- Machine Learning ;
- Deep Learning ;
- Industrialisation ;
- Restitution Power BI ;
- Documentation.

Cette structuration facilite la lisibilité globale du projet.

7.4.4 Workflow de gestion des tâches

Afin d'assurer le suivi opérationnel du projet, un workflow Jira a été mis en place pour gérer le cycle de vie des User Stories et des tâches techniques.

Chaque élément du backlog suivait les étapes suivantes :

- **Backlog** : besoin identifié mais non encore planifié ;
- **To Do** : tâche prête à être réalisée ;
- **In Progress** : développement ou traitement en cours ;
- **Review** : validation fonctionnelle et contrôle qualité ;
- **Terminé(e)** : tâche validée et clôturée.

Lorsqu'une anomalie ou une amélioration était détectée durant la phase de revue, la tâche retournait automatiquement dans l'état *In Progress* afin d'être corrigée avant une nouvelle validation.

Ce processus a permis de garantir la qualité des livrables tout en assurant une traçabilité complète de l'avancement du projet.

L'utilisation systématique de ce workflow a facilité la coordination entre les membres de l'équipe et a permis d'identifier rapidement les éventuels points de blocage.

7.4.5 Utilisation du Burndown Chart

Le suivi de l'avancement des sprints a été réalisé à l'aide du Burndown Chart proposé par Jira.

Cet indicateur permet de visualiser l'évolution du volume de travail restant au cours d'un sprint en comparant :

- la charge prévue ;
- la charge réellement consommée ;
- l'avancement effectif de l'équipe.

Le Burndown Chart a constitué un outil d'aide à la décision permettant d'anticiper les retards éventuels et d'ajuster les priorités lorsque cela était nécessaire.

Son utilisation a favorisé une meilleure visibilité sur l'état d'avancement du projet et a contribué au respect des objectifs fixés pour chaque sprint.

7.5 Réunions et coordination

7.5.1 Daily Meetings

Des réunions régulières ont été organisées tout au long du projet.

Environ soixante points d'avancement ont été réalisés sous forme de Daily Meetings.

Ces échanges ont permis :

- de partager les difficultés ;
- de suivre l'avancement ;
- d'identifier les blocages ;
- de coordonner les travaux.

7.5.2 Rétrospectives

À l'issue de chaque sprint, une rétrospective a été réalisée.

Neuf rétrospectives ont ainsi permis :

- d'identifier les points d'amélioration ;
- d'analyser les difficultés rencontrées ;
- d'ajuster les méthodes de travail.

Cette démarche d'amélioration continue constitue l'un des principes fondamentaux de la méthodologie Agile.

7.6 Documentation du projet

7.6.1 Importance de la documentation

La documentation joue un rôle essentiel dans tout projet informatique.

Elle permet :

- de transmettre les connaissances ;
- de faciliter la maintenance ;
- de conserver les décisions techniques ;
- de préparer les évolutions futures.

Une attention particulière a donc été portée à cet aspect.

7.6.2 Utilisation de Confluence

Confluence a été utilisé afin de centraliser l'ensemble des informations relatives au projet.

Les documents produits comprennent notamment :

- comptes-rendus ;
- architecture technique ;
- documentation fonctionnelle ;
- notes de sprint ;
- guides de déploiement.

Cette documentation facilite la transmission des connaissances à l'ensemble des parties prenantes.

7.6.3 Documentation GitHub

Le dépôt GitHub constitue également un élément important de la documentation.

Il contient :

- le code source ;
- les notebooks ;
- les scripts ;
- les fichiers de configuration ;
- le suivi des versions.

Cette centralisation garantit la traçabilité des développements réalisés.

7.7 Gestion des versions et traçabilité

7.7.1 Utilisation de Git

Git a été utilisé pour assurer le suivi des évolutions du projet.

Cette approche permet :

- d'historiser les modifications ;
- de revenir à une version précédente ;
- de sécuriser le développement.

7.7.2 GitHub

GitHub a été utilisé comme plateforme collaborative.

Les principaux avantages observés sont :

- centralisation du code ;
- partage entre les membres ;
- suivi des modifications ;
- gestion des versions.

Cette démarche s'inscrit dans les bonnes pratiques de développement logiciel.

7.8 Communication et vulgarisation des résultats

7.8.1 Enjeux de communication

Les résultats produits par les modèles de Machine Learning ne sont pas directement exploitables par des utilisateurs non spécialistes.

Un travail de vulgarisation est donc nécessaire afin de transformer des résultats techniques en informations compréhensibles.

Cette démarche constitue une compétence essentielle du métier de Concepteur Développeur en Science des Données.

7.8.2 Utilisation de Power BI

Power BI a été utilisé pour restituer les résultats sous forme visuelle.

Les tableaux de bord permettent :

- d'explorer les données ;
- de suivre les indicateurs ;
- de comprendre les tendances observées.

Cette restitution facilite l'appropriation des résultats par des profils métiers.

7.8.3 Interface Streamlit

Une interface utilisateur a également été développée.

Cette application permet :

- la saisie des caractéristiques du patient ;
- l'exécution de la prédiction ;
- l'affichage immédiat du résultat.

L'utilisateur n'a pas besoin de maîtriser Python ou les algorithmes utilisés.

7.9 Coordination et pilotage du projet

7.9.1 Vision globale du projet

Le projet a nécessité la coordination de nombreuses activités :

- gestion des données ;
- analyses statistiques ;
- Machine Learning ;
- Deep Learning ;
- développement logiciel ;

- déploiement cloud ;
- documentation.

Le maintien d'une vision globale de l'ensemble de ces composants a été indispensable pour garantir la cohérence de la solution.

7.9.2 Suivi des dépendances

Chaque composant du système dépend d'autres éléments :

- les modèles dépendent des données ;
- l'API dépend des modèles ;
- Streamlit dépend de l'API ;
- Power BI dépend des données préparées.

La maîtrise de ces dépendances constitue un élément central du pilotage du projet.

7.9.3 Coordination des travaux

Le pilotage a consisté à assurer la cohérence entre :

- les objectifs fonctionnels ;
- les développements techniques ;
- les contraintes pédagogiques ;
- les délais de réalisation.

Cette coordination a permis de mener le projet jusqu'à la livraison d'une solution complète et opérationnelle.

7.10 Gestion des risques

Plusieurs risques ont été identifiés durant le projet.

Risque	Impact potentiel
Volume important de données	Complexité de traitement
Variables trop nombreuses	Surapprentissage
Valeurs manquantes	Dégradation des performances
Contraintes de temps	Retards

Risque	Impact potentiel
Limites du cloud gratuit	Disponibilité réduite

Différentes mesures ont été mises en œuvre afin de limiter ces risques :

- sélection des variables ;
- automatisation des traitements ;
- documentation ;
- suivi régulier de l'avancement.

7.11 Gouvernance des données

Les données utilisées proviennent du programme de recherche ADNI.

Aucune donnée directement identifiante n'a été utilisée dans le cadre du projet.

Les informations exploitées reposent sur des identifiants pseudonymisés tels que :

- RID ;
- VISCODE.

Une attention particulière a été portée :

- à la traçabilité des traitements ;
- à la qualité des données ;
- au respect des bonnes pratiques relatives à l'utilisation des données médicales.

Ces éléments ont notamment été étudiés dans le cadre de l'analyse PIA réalisée durant le projet.

7.12 Bilan du Bloc 6

Le pilotage du projet a joué un rôle essentiel dans la réussite de la solution développée.

L'utilisation des méthodes Agile, associée à des outils tels que Jira, Confluence et GitHub, a permis :

- d'organiser les travaux ;
- de coordonner les membres de l'équipe ;
- de suivre l'avancement ;
- de documenter les réalisations ;

- de communiquer efficacement les résultats.

Cette démarche répond directement aux compétences C6.5 et C6.6 du référentiel RNCP en démontrant la capacité à transmettre des analyses à des publics non techniques tout en assurant la coordination globale d'un projet Data Science.

Le chapitre suivant présentera le bilan global du projet ainsi que les perspectives d'évolution envisagées pour une future industrialisation à plus grande échelle.

CHAPITRE 8 – CONCLUSION GÉNÉRALE ET PERSPECTIVES

8.1 Conclusion générale

Le projet de détection précoce de la maladie d'Alzheimer à partir des données ADNI a permis de mettre en œuvre l'ensemble des compétences attendues dans le cadre de la formation Concepteur Développeur en Science des Données.

L'objectif initial consistait à exploiter des données médicales complexes afin de construire une solution capable d'estimer le risque de développement de la maladie d'Alzheimer à partir d'informations cliniques, cognitives et biologiques.

Pour atteindre cet objectif, une chaîne complète de traitement de données a été conçue et déployée, couvrant l'ensemble du cycle de vie de la donnée :

- collecte ;
- ingestion ;
- stockage ;
- préparation ;
- analyse exploratoire ;
- modélisation ;
- industrialisation ;
- restitution.

L'ensemble du projet s'appuie sur les données issues de la base de recherche ADNI, reconnue comme une référence internationale dans l'étude des maladies neurodégénératives.

La première phase du projet a consisté à sélectionner les tables les plus pertinentes parmi les nombreuses sources disponibles. Les données ont ensuite été consolidées, nettoyées et préparées afin de constituer un jeu de données exploitable pour les modèles de Machine Learning.

Une attention particulière a été portée à la qualité des données. Le traitement des valeurs manquantes, la gestion des codifications spécifiques à ADNI et la sélection des variables ont représenté une part importante du travail réalisé.

Cette phase a permis de transformer un ensemble volumineux et hétérogène de données médicales en un socle cohérent et exploitable.

L'analyse exploratoire a ensuite permis d'identifier les variables les plus influentes et de mieux comprendre les relations existantes entre les différents indicateurs médicaux. Les

visualisations produites ont facilité l'interprétation des résultats et préparé les étapes de modélisation.

Plusieurs modèles de Machine Learning ont été développés puis comparés. Les résultats obtenus démontrent la pertinence de l'approche retenue.

Le modèle Random Forest a été sélectionné comme solution de référence grâce à son excellent compromis entre performance, robustesse et interprétabilité.

Les performances observées sont particulièrement satisfaisantes :

Modèle	F1-Score
Random Forest	91,96 %
Gradient Boosting	91,88 %
Keras Classifieur	91,56 %

Ces résultats montrent qu'il est possible d'obtenir une estimation fiable du risque de maladie d'Alzheimer à partir d'un nombre limité de variables soigneusement sélectionnées.

En complément, une expérimentation Deep Learning basée sur l'analyse d'images IRM cérébrales a été réalisée à l'aide d'un réseau de neurones convolutif. Cette étude a permis d'explorer le potentiel de l'imagerie médicale dans la détection des signes associés à la maladie.

Même si cette expérimentation n'est pas intégrée à la solution finale, elle constitue une ouverture intéressante vers des architectures multimodales plus avancées.

L'une des principales forces du projet réside dans son niveau d'industrialisation.

Contrairement à de nombreux projets académiques limités à la phase de modélisation, une architecture complète a été mise en œuvre :

- stockage des données dans Supabase ;
- entraînement automatisé des modèles ;
- gestion des artefacts ;
- API FastAPI ;
- interface utilisateur Streamlit ;
- conteneurisation Docker ;
- déploiement Cloud via Render ;

- visualisation Power BI.

Cette architecture permet de transformer un modèle de Machine Learning en une solution réellement exploitable.

Enfin, la conduite du projet selon une méthodologie Agile Scrum, associée à l'utilisation de Jira, Confluence et GitHub, a permis d'assurer un suivi rigoureux des travaux tout en favorisant la collaboration entre les membres de l'équipe.

L'ensemble des objectifs fixés au démarrage du projet a ainsi pu être atteint.

8.2 Apports professionnels et compétences acquises

Au-delà des résultats techniques obtenus, ce projet a constitué une expérience particulièrement enrichissante sur le plan professionnel.

Il a permis de développer des compétences dans plusieurs domaines complémentaires :

Gestion et valorisation des données

- intégration de sources multiples ;
- nettoyage et préparation des données ;
- contrôle qualité ;
- structuration des données.

Analyse de données

- statistiques descriptives ;
- analyse exploratoire ;
- visualisation ;
- interprétation des résultats.

Machine Learning

- sélection des variables ;
- entraînement des modèles ;
- évaluation des performances ;
- comparaison d'algorithmes.

Deep Learning

- traitement d'images médicales ;

- réseaux de neurones convolutifs ;
- expérimentation de modèles avancés.

Développement logiciel

- Python ;
- FastAPI ;
- Streamlit ;
- Docker.

Gestion de projet

- Scrum ;
- Jira ;
- Confluence ;
- GitHub ;
- documentation.

Cette diversité d'activités reflète la dimension pluridisciplinaire du métier de Concepteur Développeur en Science des Données.

8.3 Difficultés rencontrées

La principale difficulté du projet concerne la complexité des données ADNI.

Les données sont réparties dans de nombreuses tables et comportent plusieurs centaines de variables.

Le travail de sélection a constitué un enjeu majeur.

L'objectif n'était pas simplement d'obtenir de bonnes performances, mais également de conserver un modèle interprétable et exploitable.

La réduction du nombre de variables a nécessité :

- des analyses statistiques ;
- des comparaisons expérimentales ;
- une validation progressive des choix réalisés.

Cette étape a joué un rôle déterminant dans la qualité finale des modèles obtenus.

8.4 Perspectives d'évolution

Plusieurs axes d'amélioration ont été identifiés pour les futures évolutions du projet.

Intégration des données IRM dans l'API

L'expérimentation CNN réalisée dans le cadre du projet pourrait être intégrée directement à l'architecture existante.

L'objectif serait de combiner :

- données cliniques ;
- données cognitives ;
- données physiologiques ;
- données d'imagerie.

Cette approche multimodale pourrait permettre d'améliorer encore les performances de prédiction.

Mise en place d'une chaîne CI/CD

Le déploiement pourrait être automatisé à l'aide d'une chaîne CI/CD reposant sur GitHub Actions.

Cette évolution permettrait :

- l'automatisation des tests ;
- l'automatisation des déploiements ;
- l'amélioration de la qualité logicielle.

Monitoring et MLOps

Une autre évolution importante concerne la mise en place d'outils de suivi des modèles en production.

L'utilisation de solutions telles que MLflow permettrait :

- le suivi des performances ;
- la gestion des versions ;
- la détection du drift ;
- la supervision des modèles.

Renforcement de la sécurité et de la gouvernance

Dans une perspective de mise en production réelle, plusieurs évolutions pourraient être envisagées :

- séparation des environnements de développement, recette et production ;
- authentification des utilisateurs ;
- gestion des rôles et des droits d'accès ;
- centralisation des journaux applicatifs ;
- surveillance des performances ;
- gestion sécurisée des secrets applicatifs.

Ces éléments n'étaient pas nécessaires dans le cadre de cette preuve de concept mais constitueraient des évolutions naturelles pour une exploitation à grande échelle.

Enrichissement des données

L'ajout de nouvelles sources de données pourrait également être envisagé :

- biomarqueurs complémentaires ;
- données génétiques ;
- examens médicaux supplémentaires ;
- données hospitalières externes.

Ces enrichissements pourraient contribuer à améliorer la précision des modèles.

8.5 Considérations éthiques et réglementaires

Les données utilisées dans le cadre du projet proviennent de la base ADNI et sont pseudonymisées.

Aucune donnée directement identifiante n'a été utilisée.

Une analyse PIA a été réalisée afin d'évaluer les risques liés au traitement des données.

Enfin, il convient de rappeler que la solution développée constitue un outil d'aide à la décision.

Les résultats produits ne peuvent en aucun cas se substituer à l'expertise d'un professionnel de santé.

La décision médicale finale doit toujours être prise par un praticien qualifié.

8.6 Mot de clôture

Ce projet démontre la capacité à concevoir, développer et déployer une solution Data Science complète répondant à une problématique réelle de santé publique.

Au-delà de la performance des modèles développés, il illustre l'importance d'une approche globale intégrant la qualité des données, la compréhension métier, l'industrialisation des traitements et la communication des résultats.

L'expérience acquise au cours de ce projet constitue une base solide pour la réalisation de futurs projets de Data Science et confirme l'intérêt croissant des technologies d'intelligence artificielle dans le domaine médical.

GLOSSAIRE

ADNI

Alzheimer's Disease Neuroimaging Initiative

Programme international de recherche visant à améliorer la compréhension, le diagnostic et le suivi de la maladie d'Alzheimer à partir de données cliniques, biologiques et d'imagerie médicale.

ADAS

Alzheimer's Disease Assessment Scale

Test neuropsychologique utilisé pour évaluer la sévérité des troubles cognitifs liés à la maladie d'Alzheimer.

CDR

Clinical Dementia Rating

Échelle clinique utilisée pour mesurer le niveau de sévérité de la démence.

MMSE

Mini Mental State Examination

Test cognitif utilisé pour évaluer les capacités mentales d'un patient.

RID

Research Identifier

Identifiant unique attribué à chaque patient dans la base ADNI.

VISCODE

Code identifiant une visite médicale spécifique d'un patient dans ADNI.

MLOps

Ensemble des pratiques permettant de gérer le cycle de vie des modèles de Machine Learning en production.

Machine Learning

Ensemble de techniques permettant à un système informatique d'apprendre automatiquement à partir de données.

Random Forest

Algorithme de Machine Learning reposant sur un ensemble d'arbres de décision.

Gradient Boosting

Algorithme de Machine Learning reposant sur l'amélioration progressive des erreurs réalisées par les modèles précédents.

Deep Learning

Sous-domaine du Machine Learning reposant sur des réseaux de neurones à plusieurs couches.

Keras

Bibliothèque Python permettant de développer des modèles de Deep Learning.

CNN

Convolutional Neural Network

Réseau de neurones convolutif spécialisé dans l'analyse d'images.

Data Lake

Espace de stockage permettant de conserver des données brutes ou préparées provenant de plusieurs sources.

Dans le projet, Supabase joue ce rôle.

Power BI

Outil de visualisation et de création de tableaux de bord décisionnels.

EDA

Exploratory Data Analysis

Analyse exploratoire des données visant à comprendre leur structure avant la modélisation.

Recall

Capacité d'un modèle à identifier correctement les observations positives.

Dans un contexte médical, cette métrique est particulièrement importante pour limiter les faux négatifs.

F1-Score

Métrique combinant la précision et le rappel afin d'évaluer les performances d'un modèle de classification.

Artifact

Fichier généré lors de l'entraînement d'un modèle contenant les paramètres appris et permettant sa réutilisation sans nouvel entraînement.

Docker

Plateforme de conteneurisation permettant d'exécuter une application dans un environnement reproductible.

Git

Système de gestion de versions utilisé pour suivre les modifications du code source.

GitHub

Plateforme collaborative utilisée pour héberger et versionner le projet.

Jira

Outil de gestion de projet Agile utilisé pour suivre les User Stories, les sprints et les tâches du projet.

Render

Plateforme cloud utilisée pour déployer l'API et l'application web.

API

Application Programming Interface

Interface permettant à différentes applications de communiquer entre elles.

Dans ce projet, FastAPI permet à Streamlit d'interroger le modèle de prédiction.

Streamlit

Framework Python permettant de développer rapidement des applications web orientées Data Science.

FastAPI

Framework Python utilisé pour développer l'API de prédiction du projet.

Scrum

Méthodologie Agile basée sur l'organisation du travail en sprints.

PIA

Privacy Impact Assessment

Analyse d'impact relative à la protection des données.